

**IMPLEMENTASI *HYBRID* CNN-LSTM AUTOENCODER
UNTUK DETEKSI ANOMALI *ZERO-DAY* PADA *NETWORK-
BASED INTRUSION DETECTION SYSTEM* (NIDS)
*ENTERPRISE***

PROPOSAL SKRIPSI

diajukan untuk memenuhi sebagian syarat untuk memperoleh gelar Sarjana
Komputer pada Program Studi Rekayasa Perangkat Lunak



Oleh.

Akwan Cakra Tajimalela

NIM 2209098

**PRORAM STUDI REKAYASA PERANGKAT LUNAK
KAMPUS UPI DI CIBIRU
UNIVERSITAS PENDIDIKAN INDONESIA
2026**

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR TABEL.....	iv
DAFTAR GAMBAR	v
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian.....	4
1.4 Manfaat Penelitian	4
1.5 Batasan Penelitian	5
1.6 Sistematika Penulisan.....	6
BAB II TINJAUAN PUSTAKA	7
2.1 <i>State-of-the-art</i> Penelitian	7
2.2 <i>Intrusion Detection System</i>	11
2.2.1 <i>Taxonomy</i> IDS: NIDS vs HIDS.....	12
2.2.2 <i>Signature-based</i> IDS	13
2.2.3 <i>Anomaly-based</i> IDS	14
2.2.4 Jenis Serangan Jaringan	16
2.3 <i>Zero-Day Attack</i>	18
2.4 <i>Deep Learning</i> untuk <i>Intrusion Detection</i>	19
2.4.1 <i>Supervised</i> vs <i>Unsupervised Learning</i> dalam NIDS.....	19
2.4.2 <i>Convolutional Neural Network</i> (CNN).....	20
2.4.3 <i>Long Short-Term Memory</i> (LSTM).....	20
2.5 Autoencoder untuk <i>Anomaly Detection</i>	21
2.5.1 Arsitektur Autoencoder	22
2.5.2 <i>Reconstruction Error</i> sebagai Indikator Anomali	22
2.5.3 Keunggulan <i>Unsupervised Learning</i> untuk <i>Zero-Day Detection</i>	23
2.6 <i>Hybrid CNN-LSTM</i> Autoencoder untuk NIDS	24
2.7 <i>Cross-Dataset Validation</i>	25
2.7.1 Konsep <i>Generalization</i> dan <i>Overfitting</i>	25
2.7.2 <i>Cross-Dataset Validation Strategy</i>	25

2.8 Dataset.....	26
2.8.1 CIC-IDS2017	26
2.8.2 CSE-CIC-IDS2018.....	27
2.8.3 <i>Feature Alignment</i> dan <i>Cross-Dataset Strategy</i>	27
2.9 Metrik Evaluasi	28
2.9.1 <i>Classification Metrics</i>	28
2.9.2 ROC Curve dan AUC.....	29
2.9.3 <i>False Positive Rate (FPR)</i>	29
2.9.4 <i>Generalization Metrics</i>	29
BAB III METODOLOGI PENELITIAN.....	31
3.1 Desain Penelitian.....	31
3.1.1 Klarifikasi Penelitian.....	32
3.1.2 Studi Deskriptif I.....	32
3.1.3 Studi Preskriptif	33
3.1.4 Studi Deskriptif II	36
3.2 Instrumen Penelitian.....	39
3.3 Alat dan Bahan Penelitian	41
3.3.1 Alat Penelitian	41
3.3.2 Bahan Penelitian.....	43
DAFTAR PUSTAKA	46

DAFTAR TABEL

Table 2.1. Penelitian Terdahulu.....	9
Tabel 2.2 Klasifikasi Jenis Serangan Jaringan	16
Tabel 3.1 Spesifikasi <i>Hardware</i> Penelitian	41
Tabel 3.2 <i>Software</i> dan <i>Library</i> yang Digunakan	42
Tabel 3.3 Karakteristik Dataset CIC-IDS2017.....	43
Tabel 3.4 Karakteristik Dataset CSE-CIC-IDS2018.....	44

DAFTAR GAMBAR

Gambar 2.1 <i>Simplified Workflow Signature-based Intrusion Detection System ...</i>	13
Gambar 2.2 <i>Arsitektur Anomaly-based IDS dengan Two-Phase Detection</i>	15
Gambar 2.3 <i>Lifecycle Zero-Day Attack dan Window of Vulnerability</i>	18
Gambar 2.4 <i>Arsitektur LSTM Cell dan Temporal Sequence Processing.....</i>	21
Gambar 2.5 <i>Arsitektur Autoencoder dengan Encoder-Decoder untuk Anomaly Detection</i>	22
Gambar 2.6 <i>Arsitektur Hybrid CNN-LSTM Autoencoder untuk Zero-Day Intrusion Detection</i>	24
Gambar 3.1 <i>Design Research Methodology (DRM)</i>	31
Gambar 3.2 <i>Alur Preprocessing dan Pembentukan Data Time-Series</i>	34
Gambar 3.3 <i>Arsitektur Hybrid CNN-LSTM Autoencoder yang Diusulkan</i>	35
Gambar 3.4 <i>Skema Eksperimen Validasi Lintas Dataset (Cross-Dataset Validation)</i>	36
Gambar 3.5 <i>Ilustrasi Penentuan Threshold Deteksi Berdasarkan Distribusi Error.</i>	38

BAB I PENDAHULUAN

1.1 Latar Belakang

Vulnerabilitas CVE-2025-55182 atau React2Shell yang baru saja diumumkan pada Desember 2025 menjadi bukti bahwa sistem pertahanan tradisional masih kewalahan menghadapi ancaman *zero-day*. Dengan skor CVSS sempurna yakni 10.0, celah ini berhasil mengeksploitasi puluhan organisasi dalam waktu kurang dari 24 jam (Zugec, 2025). Data menunjukkan adanya 77.664 alamat IP yang rentan, dimana hal ini memperlihatkan kegagalan fatal dari sistem *signature-based* dalam merespons ancaman cepat. Eksploitasi ini menyerang komponen *React Server Components* yang memungkinkan penyerang melakukan *Remote Code Execution* tanpa autentikasi. Yang lebih mengkhawatirkan lagi adalah ketersediaan 72 alat *Proof-of-Concept* gratis di hari pertama, yang mana kondisi ini membuat serangan menjadi sangat mudah dilakukan (Cipollone, 2025). Fakta bahwa tingkat keberhasilan eksploitasi mencapai hampir 100% pada konfigurasi default menunjukkan betapa mendesaknya kebutuhan akan metode deteksi yang tidak bergantung pada *signature database*.

Di sisi lain, eskalasi ancaman siber global terus meningkat dengan proyeksi kerugian mencapai \$10,5 triliun pada tahun 2025 (Khalil, 2025). Tahun 2024 saja mencatat 75 kerentanan *zero-day* baru, dimana 44% diantaranya secara spesifik menargetkan sistem *enterprise* (Jay, 2025). Yang menarik adalah tren serangan yang kini menyasar perangkat keamanan seperti *firewall* dan VPN, yang mana perangkat ini seringkali memiliki akses tinggi namun minim pengawasan. Kompleksitas infrastruktur modern yang menggabungkan *cloud* dan IoT semakin memperluas *attack surface* yang ada. Masalah semakin pahit ketika melihat kesenjangan antara *dwell time* rata-rata 10 hari dengan proses eksfiltrasi data yang bisa terjadi dalam 24 jam (Help Net Security, 2024). Kondisi ini mengindikasikan bahwa organisasi tidak lagi bisa mengandalkan mekanisme pertahanan reaktif yang lambat dalam mendeteksi intrusi.

Intrusion Detection System (IDS) pada dasarnya adalah perangkat lunak yang dirancang khusus untuk memonitor lalu lintas jaringan guna mendeteksi aktivitas mencurigakan yang dapat membahayakan sistem (Scarfone & Mell, 2007). Sistem ini bekerja dengan menganalisis trafik secara *real-time* dan memberikan peringatan

dini kepada administrator agar dapat segera ditindaklanjuti (Rahmawati dkk., 2024). Sebagai sistem pertahanan, IDS berperan penting dalam menjaga aspek *Confidentiality*, *Integrity*, dan *Availability* dari serangan siber. Namun demikian, efektivitas IDS tradisional kini mulai dipertanyakan mengingat kemampuannya yang terbatas dalam menghadapi serangan terotomatisasi seperti React2Shell. Serangan modern yang mampu bermutasi dengan cepat menuntut adanya integrasi sistem deteksi yang lebih adaptif, yang mana pendekatan lama dirasa sudah tidak lagi mumpuni untuk menangani ancaman *zero-day* yang semakin canggih.

Signature-based IDS bekerja dengan cara mencocokkan lalu lintas jaringan dengan *signature database* serangan yang sudah diketahui (Ahmed dkk., 2025). Meskipun sangat akurat untuk ancaman lama, metode ini terbukti gagal total dengan tingkat deteksi 0% terhadap serangan *zero-day* karena belum adanya *signature* yang tersedia saat serangan terjadi (Sridharan dkk., 2025). Ketergantungan pada pembaruan *signature* menciptakan jeda waktu yang berbahaya, dimana penyerang bisa bebas beraksi selama periode “*blind spot*” tersebut. Kasus React2Shell menjadi contoh, yang mana puluhan ribu sistem terinfeksi hanya dalam 24 jam sementara vendor keamanan baru merilis *signature*. Selain beban operasional yang tinggi, kelemahan fundamental ini menegaskan bahwa pendekatan reaktif tidak lagi cukup untuk melindungi aset kritikal *enterprise*.

Sebagai alternatif, *Anomaly-based Intrusion Detection System* (AIDS) menawarkan pendekatan proaktif dengan mempelajari pola normal jaringan untuk mendeteksi penyimpangan (Guo, 2023). Sistem hybrid berbasis anomali dilaporkan mampu mencapai deteksi diatas 95% terhadap ancaman baru tanpa perlu menunggu *update signature* (Sridharan dkk., 2025). Meskipun menjanjikan, deteksi anomali konvensional seringkali kesulitan menangani data jaringan berdimensi tinggi dan masalah ketidakseimbangan kelas. Oleh karena itu, penerapan teknologi *deep learning* menjadi solusi yang sangat potensial untuk meningkatkan akurasi deteksi (Alsoufi dkk., 2024). Hal ini menunjukkan bahwa kombinasi antara pendekatan anomali dengan *deep learning* adalah kunci untuk mengatasi keterbatasan IDS tradisional dalam menghadapi serangan yang berkembang cepat.

Integrasi model *deep learning* terbukti sangat efektif dalam mengenali pola rumit pada lalu lintas jaringan. Arsitektur CNN-LSTM misalnya, memanfaatkan CNN untuk mengekstrak fitur spasial dan LSTM untuk menangkap pola urutan waktu, yang mana kombinasi ini mampu mencapai akurasi 99,64% di dataset CIC-IDS2017 (Halbouni dkk., 2022). Sementara itu, Autoencoder unggul dalam mendeteksi anomali tanpa label serangan dengan cara mengukur *reconstruction error* dari data input (Alsoufi dkk., 2024). Penggabungan *supervised* dan *unsupervised learning* ini menghasilkan sistem pertahanan yang kuat. Dari berbagai penelitian yang ada, dapat dilihat bahwa pendekatan *hybrid* ini memiliki potensi besar untuk mendeteksi serangan *zero-day* secara real-time sebelum kerusakan fatal terjadi.

Berdasarkan permasalahan tersebut, penelitian ini mengusulkan Implementasi *Hybrid CNN-LSTM Autoencoder Untuk Deteksi Anomali Zero-Day Pada Network-Based Intrusion Detection System (NIDS) Enterprise*. Berbeda dengan pendekatan *signature-based* yang gagal merespons React2Shell, metode ini menggunakan *unsupervised learning* untuk mengenali deviasi trafik secara mandiri (Almuhanna & Dardouri, 2025). Model ini akan dilatih menggunakan *dataset* CIC-IDS2017 dan diuji validitasnya pada CSE-CIC-IDS2018 untuk mengukur kemampuan generalisasi terhadap serangan baru (*cross-dataset validation*). Fokus utamanya adalah mengisi celah penelitian sebelumnya yang seringkali hanya menggunakan satu dataset saja. Dengan target akurasi diatas 90% pada data baru, sistem ini diharapkan mampu memberikan perlindungan proaktif dan mengurangi *dwell time* serangan secara signifikan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana performa model *Hybrid CNN-LSTM Autoencoder* dalam mendeteksi serangan siber pada dataset CIC-IDS2017 dibandingkan dengan *baseline methods*?
2. Bagaimana kemampuan generalisasi model *Hybrid CNN-LSTM Autoencoder* dalam mendeteksi serangan *zero-day* melalui *cross-dataset*

validation menggunakan *dataset* CSE-CIC-IDS2018 dengan perbandingan skenario *zero-shot* dan *few-shot adaptation*?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah di atas, berikut adalah tujuan dari penelitian ini:

1. Mengevaluasi performa model *Hybrid* CNN-LSTM Autoencoder dalam mendeteksi serangan siber pada dataset CIC-IDS2017 dan membandingkannya dengan *baseline methods*.
2. Menganalisis kemampuan generalisasi model *Hybrid* CNN-LSTM Autoencoder dalam mendeteksi serangan *zero-day* melalui *cross-dataset validation* menggunakan *dataset* CSE-CIC-IDS2018 dengan membandingkan skenario *zero-shot* dan *few-shot adaptation*.

1.4 Manfaat Penelitian

Adapun manfaat dari penelitian yang akan dilakukan, sebagai berikut:

1. Manfaat Teoritis:
 - a. Memberikan kontribusi metode baru dalam pengembangan *Anomaly-based Intrusion Detection System* menggunakan pendekatan *Hybrid* CNN-LSTM Autoencoder untuk deteksi *zero-day attacks*.
 - b. Menambah literatur dan pemahaman mengenai penerapan *deep learning* pada deteksi anomali lalu lintas jaringan tanpa bergantung pada *signature database*.
 - c. Menyediakan bukti empiris mengenai kemampuan generalisasi model *deep learning* melalui *cross-dataset validation* dalam domain *cybersecurity*.
2. Manfaat Praktis:
 - a. Menghasilkan model *Intrusion Detection System* yang mampu mendeteksi *zero-day* secara *real-time* tanpa bergantung pada *signature database*.
 - b. Membantu organisasi *enterprise* dalam memperkuat pertahanan jaringan dengan mengurangi *dwell time* deteksi serangan.

- c. Mengurangi beban operasional dan biaya pemeliharaan sistem keamanan dengan meminimalkan ketergantungan pada pembaruan *signature* secara manual.

1.5 Batasan Penelitian

Dalam pelaksanaan penelitian, batasan penelitian yang ditetapkan sebagai berikut:

1. Dataset yang digunakan terbatas pada CIC-IDS2017 dan CSE-CIC-IDS2018 yang merupakan dataset publik hasil simulasi jaringan enterprise, bukan *real-time traffic* dari lingkungan produksi.
2. Arsitektur model yang dikembangkan terbatas pada *Hybrid CNN-LSTM Autoencoder* tanpa melakukan eksplorasi terhadap arsitektur lainnya seperti *Transformer*, GRU, atau *Attention Mechanism*.
3. Perbandingan performa model dibatasi pada dua *baseline methods*, yaitu LSTM Autoencoder dan *Traditional Machine Learning (Isolation Forest/Random Forest)*, tanpa membandingkan dengan metode *Signature-based IDS* atau *anomaly detection* lainnya.
4. Proses *training* model menggunakan pendekatan *unsupervised learning* yang hanya memanfaatkan data normal *traffic* (benign), tanpa menggunakan *labelled attack data* dalam fase *training*.
5. Evaluasi performa model dibatasi pada *binary classification (Normal vs Attack)* menggunakan *standard classification*, AUC-ROC, *False Positive Rate*, dan *generalization metrics*, tanpa melakukan klasifikasi *multi-class* untuk jenis serangan spesifik.
6. Adaptasi model (*fine-tuning*) dilakukan secara *unsupervised* menggunakan sebagian kecil data target (<1% data) tanpa melakukan *advanced feature engineering* yang kompleks.
7. Implementasi sistem dilakukan dalam *environment offline* untuk eksperimen dan evaluasi, bukan *deployment real-time* pada infrastruktur jaringan enterprise yang aktif.

1.6 Sistematika Penulisan

Berikut merupakan sistematika penulisan yang ada pada penelitian ini, diantaranya sebagai berikut:

1. BAB I PENDAHULUAN

Bab ini menguraikan latar belakang masalah, rumusan masalah penelitian, tujuan yang ingin dicapai, manfaat penelitian, batasan penelitian, dan sistematika penulisan.

2. BAB II KAJIAN PUSTAKA

Bab ini membahas teori-teori dan konsep yang relevan dengan topik penelitian, serta kajian terhadap penelitian-penelitian sebelumnya yang berkaitan untuk menggambarkan posisi dan kontribusi penelitian ini dalam *state-of-the-art*.

3. BAB III METODE PENELITIAN

Bab ini menjelaskan pendekatan dan metode penelitian yang digunakan, serta memaparkan tahapan-tahapan pelaksanaan penelitian secara sistematis dari tahap awal sampai tahap akhir.

4. BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil eksperimen dan temuan penelitian, serta pembahasan mendalam yang menjawab rumusan masalah yang telah ditetapkan.

5. BAB V PENUTUP

Bab ini memaparkan kesimpulan berdasarkan hasil penelitian, implikasi dari temuan penelitian, serta saran untuk pengembangan penelitian selanjutnya.

BAB II TINJAUAN PUSTAKA

2.1 *State-of-the-art* Penelitian

Penelitian ini merujuk pada beberapa penelitian terdahulu yang menjadi acuan penting dalam penelitian ini. Penjelasan di bawah ini menunjukkan *research gap* yang ada serta posisi *state-of-the-art* dari topik yang diangkat, sehingga dapat memberikan gambaran yang lebih jelas mengenai kontribusi penelitian ini terhadap pengembangan bidang deteksi intrusi *zero-day*.

Pada penelitian yang dilakukan oleh Park dkk (2025) bertujuan untuk meneliti deteksi anomali pada paket jaringan dengan fokus utama pada serangan yang belum pernah terlihat sebelumnya (*unseen attacks*). Penelitian ini menggunakan model *Hybrid CNN-BiLSTM* Autoencoder berbasis *unsupervised learning*, dimana model hanya dilatih menggunakan data normal saja pada dataset CIC-IDS2018 tanpa menggunakan data serangan dalam proses training. Proses *preprocessing* yang dilakukan cukup komprehensif, meliputi penghapusan nilai NaN, normalisasi *IP address*, hingga *Min-Max scaling* untuk standarisasi data. Hasil penelitian menunjukkan performa yang sangat baik dengan akurasi mencapai 98,1% dan *F1-score* sebesar 98,3% pada deteksi *unseen attacks*. Namun demikian, penelitian ini masih memiliki keterbatasan karena belum membandingkan model dengan metode *meta-learning* atau menerapkan *attention mechanism* yang dapat meningkatkan akurasi deteksi secara lebih baik lagi.

Sementara itu, Almuhanha & Dardouri (2025) mengambil pendekatan yang agak berbeda dengan mengembangkan sistem IDS berbasis *Hybrid Ensemble* yang sangat kompleks. Sistem ini menggabungkan kekuatan lima algoritma sekaligus yaitu XGBoost, *Random Forest*, GNN, LSTM, dan Autoencoder dalam satu kerangka kerja terintegrasi yang dilatih pada dataset CIC-IDS2017. Untuk menangani masalah data yang tidak seimbang, mereka menerapkan teknik SMOTE *balancing* yang dikombinasikan dengan *feature engineering* yang mendalam. Meskipun hasil evaluasi *5-fold cross-validation* menunjukkan performa sempurna dengan akurasi dan *F1-score* mencapai 100%, kompleksitas arsitektur ini membuat beban komputasi yang sangat tinggi. Kondisi ini mengindikasikan bahwa model tersebut mungkin kurang praktis untuk diimplementasikan pada perangkat jaringan dengan sumber daya terbatas yang membutuhkan respons *real-time*.

Dalam konteks keamanan jaringan IoT dan 5G yang semakin kompleks Baidar dkk (2025) mengusulkan arsitektur *Hybrid Deep Learning* yang digabungkan dengan konsep *Federated Learning*. Mereka memanfaatkan model CNN-BiLSTM Autoencoder dengan strategi *supervised learning* yang diperkuat oleh mekanisme rekonstruksi mandiri (*self-supervised*) pada dataset UNSW-NB15. Evaluasi model menunjukkan hasil yang mantap dengan AUC-ROC mencapai 99,59%, yang mana angka ini didukung oleh *preprocessing* data yang ekstensif mulai dari *encoding* fitur hingga penanganan *outlier*. Namun demikian, ketergantungan utama model ini pada data berlabel menjadi kelemahan tersendiri saat menghadapi ancaman *zero-day* yang dinamis. Hal ini menunjukkan bahwa sekuat apapun model *supervised*, ia akan selalu kesulitan mengenali jenis serangan baru yang pola atau *signature*-nya belum tersimpan di dalam database pelatihan.

Penelitian selanjutnya oleh Singh & Jang (2022) menawarkan perspektif lain dengan mengembangkan model MSCNN-LSTM-AE yang dirancang khusus untuk menangkap korelasi spasial dan temporal dari trafik jaringan secara simultan. Menggunakan pendekatan *unsupervised learning*, model ini mengintegrasikan *Multi-Scale CNN* untuk ekstraksi fitur spasial dan *Isolation Forest* sebagai mekanisme koreksi *error* otomatis pada tiga dataset berbeda termasuk CICDDoS2019. Hasil eksperimen menunjukkan performa yang sangat baik dengan akurasi 99,56% pada deteksi serangan DDoS. Yang perlu dicermati adalah penggunaan *threshold* rekonstruksi yang bersifat statis dalam penelitian ini, dimana hal tersebut bisa menjadi kaku saat menghadapi fluktuasi trafik jaringan yang dinamis. Kondisi ini menegaskan pentingnya mekanisme *threshold* yang adaptif agar sistem tidak mudah memicu *false alarm* akibat perubahan pola normal jaringan yang wajar.

Penelitian lain oleh Halbouni dkk (2022) berfokus pada pengembangan IDS menggunakan arsitektur Hybrid CNN-LSTM standar dengan paradigma *supervised learning* untuk membedakan trafik *benign* dan *malicious*. Model ini menerapkan teknik regularisasi seperti *batch normalization* dan *dropout* untuk mencegah *overfitting* saat dilatih pada dataset CIC-IDS2017 dan UNSW-NB15. Meskipun berhasil mencatat akurasi 99,59% pada CIC-IDS2017, analisis lebih dalam menunjukkan bahwa tingkat deteksi (*detection rate*) masih rendah untuk

kategori serangan minoritas seperti *Web Attacks* dan *Backdoor*. Hal ini memperlihatkan bahwa model berbasis *deep learning* sekalipun masih rentan terhadap bias kelas mayoritas jika tidak ditangani dengan strategi *sampling* yang tepat. Oleh karena itu, performa tinggi pada akurasi global seringkali menutupi kelemahan model dalam mendeteksi jenis serangan yang langka namun mematikan. Seluruh data terkait *state-of-the-art* penelitian ini dirangkum dalam Tabel 2.1.

Table 2.1. Penelitian Terdahulu

Penulis	Model/Arsitektur	Dataset	<i>Learning Paradigm</i>	Metode Evaluasi & Hasil
Park dkk (2025)	Hybrid CNN-BiLSTM Autoencoder	CIDS2018	Unsupervised (trained on normal only)	Accuracy: 98.1% F1-Score: 98.3%
Almuhanna & Dardouri (2025)	Hybrid Ensemble (XGBoost + RF + GNN + LSTM + Autoencoder)	CICIDS2017	Supervised + Unsupervised (Hybrid)	Accuracy: ~100% Precision: 100%, Recall: 100%, F1-Score: 100% 5-fold cross-validation
Baidar dkk (2025)	Hybrid Deep Learning-Federated Learning (CNN-BiLSTM-AE)	UNSW-NB15	Supervised + Federated Learning	Accuracy: 97.12%, Precision: 98.45%, Recall: 96.29%, F1-Score: 97.36%, AUC-ROC: 99.59%

(Singh & Jang, 2022)	MSCNN-LSTM-AE (Multi-Scale CNN-LSTM Autoencoder)	NSL-KDD, UNSW-NB15, CICDDoS2019	Unsupervised	CICDDoS2019 : Accuracy: 99.56%, Precision: 98.91%, Recall: 98.81%, F1-Score: 98.46%
Halbouni dkk (2022)	Hybrid CNN-LSTM	CIC-IDS2017, UNSW-NB15, WSN-DS	Supervised	CIC-IDS2017: 99.59% UNSW-NB15: 93.68% WSN-DS: 99.64%
Proposed	Hybrid CNN-LSTM Autoencoder	CIC-IDS2017 (training) CSE-CIC-IDS2018 (testing)	Unsupervised (normal traffic only)	Accuracy, Precision, Recall, F1-Score, AUC-ROC, False Positive Rate (FPR)

Berdasarkan tinjauan mendalam terhadap penelitian-penelitian di atas sebagaimana dirangkum dalam Tabel 2.1, terlihat adanya beberapa kesenjangan atau *research gap* yang cukup krusial. Pertama, mayoritas penelitian seperti Park dkk (2025) dan Singh & Jang (2022) hanya menguji model mereka pada satu dataset (*single dataset scenario*), yang mana hal ini belum cukup untuk membuktikan kemampuan generalisasi model terhadap lingkungan jaringan yang berbeda-beda. Kedua, dominasi pendekatan *supervised learning* pada studi Almuhanha & Dardouri (2025) membuat sistem menjadi reaktif dan sangat bergantung pada ketersediaan data label serangan terbaru. Selain itu, aspek efisiensi komputasi seringkali dikesampingkan demi mengejar akurasi semata, padahal ini adalah faktor kunci untuk implementasi pada *real-world*. Kondisi ini menunjukkan bahwa masih

dibutuhkan studi yang tidak hanya fokus pada akurasi deteksi anomali, tetapi juga pada kemampuan adaptasi model terhadap data baru yang belum pernah dilihat sebelumnya.

Berdasarkan gap yang telah diidentifikasi tersebut, penelitian ini mengusulkan model *Hybrid CNN-LSTM Autoencoder* berbasis *unsupervised learning* untuk mengatasi keterbatasan yang ada. Model ini dilatih hanya menggunakan trafik normal dari dataset CIC-IDS2017 dan diuji pada dataset CSE-CIC-IDS2018 untuk mensimulasikan deteksi *zero-day* melalui *cross-dataset validation*, yang mana pendekatan ini dapat memvalidasi kemampuan generalisasi model terhadap ancaman baru. Dalam arsitektur yang diusulkan, CNN digunakan untuk ekstraksi fitur spasial dari data jaringan, LSTM untuk pemodelan fitur temporal yang menangkap pola sekuensial, dan arsitektur Autoencoder untuk deteksi anomali berbasis *reconstruction error* yang tidak memerlukan label serangan. Evaluasi dilakukan secara mendalam menggunakan berbagai metrik seperti Akurasi, Presisi, *Recall*, *F1-Score*, AUC-ROC, hingga FPR untuk memastikan model mampu mendeteksi serangan *zero-day* dengan tingkat *false alarm* yang rendah dan dapat diimplementasikan pada jaringan *enterprise* secara efektif.

2.2 Intrusion Detection System

Intrusion Detection System (IDS) merupakan sebuah sistem yang dirancang secara khusus untuk memonitor aktivitas jaringan atau sistem komputer, dimana tujuannya adalah untuk mendeteksi tanda-tanda intrusi, pelanggaran kebijakan keamanan, atau aktivitas mencurigakan lainnya yang berpotensi membahayakan integritas sistem (Scarfone & Mell, 2007). Sistem ini memiliki peran yang sangat krusial dalam melindungi tiga pilar keamanan informasi (*CIA Triad*) dari berbagai bentuk ancaman siber yang terus berkembang, yang mana ia berfungsi sebagai komponen pertahanan berlapis dalam arsitektur keamanan jaringan modern (Aljanabi dkk., 2021; Mohapatra dkk., 2023). Berdasarkan metode deteksinya, IDS dapat diklasifikasikan menjadi dua jenis utama yaitu *signature-based* dan *anomaly-based*, yang mana keduanya memiliki karakteristik dan keunggulan masing-masing yang berbeda dalam mendeteksi dan menangani ancaman siber (Ahmed dkk., 2025). Selain itu, pengkategorian IDS juga dapat dilihat dari beberapa aspek lain

yang memiliki karakteristik serta aplikasi berbeda dalam lingkungan jaringan. Dari segi implementasi, IDS dapat dibedakan berdasarkan penempatannya yang disesuaikan dengan topologi jaringan organisasi, seperti *Network-based* IDS (NIDS) yang memantau lalu lintas jaringan dan *Host-based* IDS (HIDS) yang memantau aktivitas pada host individu.

2.2.1 Taxonomy IDS: NIDS vs HIDS

Intrusion Detection System (IDS) secara umum dapat diklasifikasikan menjadi dua kategori utama, yaitu *Network-based Intrusion Detection System* (NIDS) dan *Host-based Intrusion Detection System* (HIDS), dimana pembagian ini didasarkan pada lokasi monitoring serta sumber data yang dianalisis (Almuhanna & Dardouri, 2025; Scarfone & Mell, 2007). NIDS bekerja dengan memonitor lalu lintas jaringan secara *real-time* dengan cara menganalisis paket data yang melewati titik strategis dalam infrastruktur jaringan, sedangkan HIDS beroperasi pada *level host* atau *endpoint* dengan memantau sistem file, log aktivitas, dan proses yang berjalan di dalam *host* tersebut (Alsoufi dkk., 2024). Pendekatan NIDS memungkinkan identifikasi serangan yang memengaruhi banyak *host* sekaligus, seperti serangan DDoS atau *port scanning*, sementara HIDS lebih efektif untuk mendeteksi serangan yang bersifat internal atau berbasis *privilege escalation* (Al-Jamali dkk., 2025; Baidar dkk., 2025).

NIDS memiliki karakteristik utama berupa analisis lalu lintas jaringan menggunakan metode *packet inspection* dan *flow-based monitoring*. Prosesnya mencakup *packet capture* melalui mekanisme *port mirroring*, *network TAP*, atau *inline deployment*, kemudian data dikumpulkan untuk dianalisis menggunakan pendekatan *flow-based* (misalnya NetFlow, IPFIX) atau *packet-based* (*deep packet inspection*) (Cantone dkk., 2024; Park dkk., 2025). NIDS sangat efektif dalam mendeteksi serangan yang bersifat eksternal atau berbasis jaringan, namun memiliki keterbatasan dalam mengamati aktivitas internal yang terenkripsi atau bersifat *host-specific* (Alsoufi dkk., 2024). Selain itu, NIDS modern telah mengintegrasikan teknologi *machine learning* dan *deep learning* untuk mendeteksi anomali dalam lalu lintas jaringan yang kompleks secara otomatis, sehingga

meningkatkan kemampuan deteksi terhadap *zero-day attacks* (Almuhanna & Dardouri, 2025; Singh & Jang, 2022).

Sebaliknya, HIDS melakukan deteksi berdasarkan *event logs*, *file integrity*, dan sistem *call monitoring* untuk mengidentifikasi perilaku abnormal pada *host* tertentu (Sridharan dkk., 2025). HIDS menawarkan visibilitas yang lebih dalam terhadap aktivitas sistem internal, seperti modifikasi *file* atau *privilege misuse*, namun memiliki keterbatasan dalam mendeteksi serangan yang melibatkan beberapa *node* jaringan (Guo, 2023). Perbandingan antara keduanya menunjukkan bahwa NIDS lebih unggul dalam cakupan dan skalabilitas, sedangkan HIDS lebih unggul dalam kedalaman analisis *per-host*. Fokus penelitian modern saat ini lebih mengarah pada pengembangan NIDS berbasis *deep learning*, hal ini dikarenakan meningkatnya kebutuhan deteksi *real-time* terhadap trafik jaringan yang beragam (Almuhanna & Dardouri, 2025; Baidar dkk., 2025; Park dkk., 2025).

2.2.2 Signature-based IDS

Signature-based Intrusion Detection System merupakan metode deteksi intrusi yang bekerja dengan cara mencocokkan pola aktivitas jaringan atau sistem dengan database *signature* yang telah dikenali sebelumnya (Scarfone & Mell, 2007). *Signature* dalam konteks ini merujuk pada karakteristik spesifik dari serangan siber, seperti *byte sequence*, *header pattern*, atau *behavioral fingerprint* yang unik untuk setiap jenis ancaman (Ahmed dkk., 2025). Mekanisme kerjanya dimulai dengan proses inspeksi terhadap paket data yang melewati jaringan menggunakan teknik *pattern matching* seperti *string matching* atau *regular expression*, kemudian membandingkannya dengan database *signature* yang terus diperbarui oleh vendor keamanan atau *security researchers* (Kristi dkk., 2025). Gambar 2.1 mengilustrasikan bagaimana alur kerja lengkap dari *signature-based IDS* mulai dari *packet capture* hingga *decision making process*.



Gambar 2.1 *Simplified Workflow Signature-based Intrusion Detection System*


Beberapa alat yang umum digunakan dalam implementasi metode ini adalah Snort dan Suricata, yang mana alat ini sering dijadikan objek studi dan rujukan dalam pengembangan sistem NIDS (Ghazi dkk., 2024). Ketika pola yang cocok ditemukan, sistem akan memicu *alert* dan melakukan respons yang telah dikonfigurasi, seperti *blocking*, *logging*, atau notifikasi kepada administrator (Rahmawati dkk., 2024).

Metode *signature-based* ini memiliki beberapa keunggulan, terutama dalam hal akurasi deteksi yang tinggi untuk serangan yang sudah dikenali dan *false positive rate* yang rendah karena deteksi didasarkan pada pola yang telah terverifikasi, dengan *precision rate* mencapai 95-99% untuk *known attacks* (Ahmed dkk., 2025). Dari sisi efisiensi komputasi, metode ini dapat bekerja secara *real-time* dengan *latency* minimal untuk pola serangan yang sudah diketahui, namun efisiensi ini terbatas pada ancaman yang telah teridentifikasi sebelumnya (Achbarou dkk., 2025). Di sisi lain, *signature-based* IDS memiliki keterbatasan signifikan dalam mendeteksi *zero-day attacks* atau serangan yang menggunakan teknik *evasion* seperti *polymorphic malware* dan *obfuscation*, dikarenakan *signature* untuk ancaman tersebut belum tersedia dalam database (Al-Jamali dkk., 2025; Guo, 2023). Selain itu, sistem ini memerlukan pembaruan database *signature* secara berkala yang mengakibatkan beban operasional tinggi dan adanya *vulnerability window* yang berkisar 12-48 jam antara waktu *disclosure* dan distribusi *signature patch* (Sridharan dkk., 2025).

2.2.3 Anomaly-based IDS

Anomaly-based Intrusion Detection System adalah pendekatan deteksi intrusi yang berfokus pada identifikasi penyimpangan dari pola perilaku normal yang telah dipelajari oleh sistem (Scarfone & Mell, 2007). Berbeda dengan *signature-based* yang mengandalkan database pola serangan, *anomaly-based* IDS membangun profil *baseline* aktivitas normal melalui *fase learning* atau *training period* menggunakan data historis lalu lintas jaringan (Almuhanha & Dardouri, 2025). Pembangunan profil *baseline* yang akurat membutuhkan *dataset* yang cukup representatif untuk menangkap variasi dalam pola lalu lintas normal. Mekanisme

deteksi didasarkan pada asumsi bahwa aktivitas intrusi akan menghasilkan pola yang berbeda secara signifikan dari perilaku normal, baik dari segi *volume traffic*, frekuensi akses, maupun karakteristik protokol komunikasi (Guo, 2023). Gambar 2.2 menunjukkan arsitektur dua fase dari *anomaly-based IDS*, yaitu *training phase* untuk membangun *baseline* dan *detection phase* untuk identifikasi anomali.



Gambar 2.2 Arsitektur *Anomaly-based IDS* dengan *Two-Phase Detection*

Untuk melakukan deteksi anomali ini, metode statistik seperti *Z-score analysis*, *threshold-based detection*, dan *probabilistic models* sering digunakan dalam pendekatan tradisional, sementara teknik *machine learning* dan *deep learning* menjadi tren modern untuk meningkatkan akurasi deteksi (Alsoufi dkk., 2024).

Kelebihan utama pendekatan ini adalah kemampuannya mendeteksi *zero-day attacks* dan *novel attack variants* tanpa memerlukan *signature* yang telah didefinisikan sebelumnya, sehingga memberikan perlindungan proaktif terhadap ancaman yang belum dikenali dengan *detection rate* 70-85% untuk *unknown threats* (Al-Jamali dkk., 2025). Namun, *anomaly-based IDS* juga menghadapi

beberapa tantangan, terutama dalam hal tingginya *false positive rate* yang dapat mencapai 10-30%, karena aktivitas *legitimate* yang tidak biasa seperti *software updates*, *system maintenance*, atau perubahan pola kerja dapat salah diidentifikasi sebagai ancaman (Ahmed dkk., 2025). Efektivitas sistem sangat bergantung pada kualitas *data training* dan representativitas *baseline*, dimana profil yang tidak akurat dapat menyebabkan *detection rate* yang rendah atau *missed attacks* (Almuhanha & Dardouri, 2025). Untuk mengatasi tantangan ini, penggunaan teknik *machine learning* seperti *Random Forest*, *SVM*, dan *deep learning architectures* telah terbukti meningkatkan akurasi *anomaly detection* hingga 95% dengan kemampuan *feature extraction* dan *pattern recognition* yang lebih canggih (Alsoufi dkk., 2024).

2.2.4 Jenis Serangan Jaringan

Serangan jaringan dapat diklasifikasikan berdasarkan tujuan, metode eksekusi, dan dampaknya terhadap sistem target (Roy dkk., 2025). Pemahaman terhadap karakteristik setiap kategori serangan sangat penting dalam merancang mekanisme deteksi yang efektif, karena setiap jenis serangan memiliki *signature* dan *behavioral pattern* yang berbeda (Ahmed dkk., 2025). *Dataset benchmark* seperti CIC-IDS2017 dan CSE-CIC-IDS2018 yang digunakan dalam penelitian ini mencakup berbagai kategori serangan, dimana kategori-kategori ini digunakan untuk menguji kemampuan generalisasi model IDS. Tabel 2.2 menunjukkan klasifikasi jenis serangan jaringan beserta karakteristik dan dampaknya.

Tabel 2.2 Klasifikasi Jenis Serangan Jaringan

Kategori Serangan	Jenis Serangan	Karakteristik Traffic	Target/Dampak	Rujukan
DoS/DdoS	SYN Flood, UDP Flood, HTTP Flood	High volume traffic, bandwidth exhaustion	Resource depletion (bandwidth, CPU, memory), service unavailability	Kristi dkk., 2025


Penetration Attacks	Brute Force, Port Scanning, Vulnerability Exploitation	Sequential connection attempts, port probing patterns	Unauthorized access, privilege escalation	Ahmed dkk., 2025
Web-based Attacks	SQL Injection, XSS, RCE	Malicious payload in HTTP requests, abnormal query patterns	Data theft, code execution, system compromise	Rahmawati dkk., 2024
Botnet Attacks	Command & Control (C2), DdoS-as-a-Service, Cryptojacking	Coordinated multi-source traffic, periodic beaconing	Distributed attacks, resource hijacking, spam distribution	Alsoufi dkk., 2024
Infiltration Attacks	Backdoor, Trojan, APT	Low-and-slow traffic, encrypted channels, lateral movement	Persistent access, data exfiltration, long-term espionage	Almuhanha & Dardouri, 2025

Berdasarkan tren keamanan siber saat ini, serangan *Distributed Denial of Service* (DdoS) tetap menjadi ancaman yang signifikan dengan skala yang semakin masif. Di samping itu, serangan berbasis web terus berevolusi melalui pemanfaatan kerentanan *zero-day* yang menargetkan berbagai *framework* modern, sehingga menjadi tantangan besar bagi sistem keamanan tradisional (Yaddala & Sunkara, 2024). Meningkatnya kompleksitas serangan siber ini menuntut penggunaan IDS berbasis anomali, yang mana harus mampu mendeteksi perubahan perilaku kecil dan ancaman baru pada lalu lintas jaringan secara efektif (Yaddala & Sunkara, 2024).

2.3 Zero-Day Attack

Zero-day attack adalah serangan siber yang mengeksploitasi celah keamanan perangkat lunak yang belum diketahui vendor atau belum memiliki *patch* resmi (Guo, 2023). Istilah “*zero-day*” merujuk pada fakta bahwa pengembang punya nol hari untuk memperbaiki kerentanan sebelum dieksploitasi, menciptakan *window of vulnerability* yang sangat berisiko (Al-Jamali dkk., 2025). Karakteristik paling berbahaya dari serangan ini adalah sifatnya yang tidak terdeteksi oleh sistem *signature-based*, karena belum ada pola yang tercatat untuk ancaman ini (Ahmed dkk., 2025). Dampaknya sangat signifikan, dimana statistik menunjukkan sebagian besar *data breaches* berawal dari eksploitasi celah yang tak dikenal ini (Guo, 2023).

Siklus hidup *zero-day attack* dimulai dari penemuan kerentanan, pembuatan kode exploit, hingga serangan ke target, yang mana proses ini bisa berlangsung berbulan-bulan sebelum terdeteksi (Guo, 2023). Gambar 2.3 mengilustrasikan tahapan lifecycle serangan zero-day ini.



Gambar 2.3 *Lifecycle Zero-Day Attack dan Window of Vulnerability*

Sistem deteksi berbasis *signature* secara fundamental tidak efektif menghadapi *zero-day attack* karena tidak ada referensi pencocokan serangan baru (Sridharan dkk., 2025). Meski akurat untuk serangan lama, kelemahan ini membuat sistem buta terhadap ancaman baru (Ahmed dkk., 2025). Oleh karena itu, tantangan ini mendorong pengembangan deteksi berbasis anomali menggunakan *deep learning* yang mampu mengenali penyimpangan perilaku tanpa bergantung *signature* (Al-Jamali dkk., 2025). Model *hybrid* seperti CNN-LSTM Autoencoder terbukti menjanjikan dalam mendeteksi *zero-day attack* dengan mempelajari pola normal jaringan secara mendalam (Park dkk., 2025).

2.4 Deep Learning untuk Intrusion Detection

Deep learning telah menjadi salah satu pendekatan utama dalam pengembangan *Intrusion Detection System* modern, dimana hal ini dikarenakan kemampuannya melakukan *automatic feature extraction* dan *pattern recognition* dari *high-dimensional network traffic data* tanpa memerlukan manual *feature engineering* (Almuhanna & Dardouri, 2025; Alsoufi dkk., 2024). Arsitektur *deep neural networks* yang terdiri dari banyak *hidden layers* memungkinkan model menangkap hubungan *non-linear* yang kompleks pada data lalu lintas, sehingga meningkatkan akurasi deteksi terhadap serangan tingkat lanjut (Park dkk., 2025). Implementasi *deep learning* dalam NIDS dapat dikategorikan berdasarkan paradigma pembelajarannya yang digunakan, yaitu *supervised learning* yang memerlukan data berlabel untuk tugas klasifikasi, dan *unsupervised learning* yang mendeteksi anomali berdasarkan *reconstruction error* (Alsoufi dkk., 2024). Pendekatan *hybrid* yang menggabungkan beberapa arsitektur seperti CNN-LSTM atau CNN-Autoencoder telah menunjukkan performa unggul dengan akurasi mencapai 98-100% pada berbagai data uji (Almuhanna & Dardouri, 2025; Park dkk., 2025). Namun, penerapan *deep learning* juga menghadapi tantangan seperti komputasi yang tinggi, kebutuhan data *training* dalam jumlah besar, dan *interpretability issues* (Baidar dkk., 2025).

2.4.1 Supervised vs Unsupervised Learning dalam NIDS

Supervised learning melatih model menggunakan dataset berlabel dimana setiap data memiliki kelas seperti “normal” atau jenis serangan spesifik, sehingga menghasilkan presisi tinggi dengan akurasi 97-99% pada uji *in-distribution* (Alsoufi dkk., 2024; Baidar dkk., 2025). Namun, pendekatan ini bergantung pada ketersediaan data berlabel yang sulit dan mahal diperoleh dalam domain *cybersecurity*, serta cenderung mengalami *poor generalization* terhadap *zero-day attacks* yang tidak terwakili dalam data latih (Guo, 2023; Park dkk., 2025). Di sisi lain, *unsupervised learning* tidak memerlukan data berlabel dan bekerja dengan mengidentifikasi *anomalies* berdasarkan deviasi dari perilaku normal yang dipelajari, sehingga mampu mengidentifikasi serangan baru dan ancaman *zero-day*.

tanpa memerlukan sampel serangan (Al-Jamali dkk., 2025; Park dkk., 2025). Namun, pendekatan *unsupervised* umumnya menghasilkan *false positive rate* yang lebih tinggi, karena pola lalu lintas normal yang jarang terjadi sering dianggap anomali (Almuhanha & Dardouri, 2025). Pendekatan *hybrid* yang menggabungkan kedua paradigma yang telah diusulkan untuk mengoptimalkan kekurangan antara akurasi deteksi dan kapabilitas generalisasi (Sridharan dkk., 2025).


2.4.2 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) adalah arsitektur *deep learning* yang kini banyak diadopsi dalam NIDS untuk mengekstraksi fitur spasial dari data lalu lintas jaringan (Alsoufi dkk., 2024). Data jaringan direpresentasikan sebagai matriks, kemudian *convolution layer* menerapkan filter untuk menangkap pola lokal signifikan secara otomatis (Almuhanha & Dardouri, 2025; Park dkk., 2025).

Keunggulan CNN adalah kemampuannya menyederhanakan fitur dan mengenali pola serangan meskipun posisinya berbeda (*translation invariance*) (Alsoufi dkk., 2024; Baidar dkk., 2025). Banyak studi menunjukkan NIDS berbasis CNN mencapai akurasi tinggi pada dataset uji (Alsoufi dkk., 2024). Namun, karena kurang optimal menangkap ketergantungan waktu, CNN sering dikombinasikan dengan model sekuensial seperti LSTM (Park dkk., 2025).

2.4.3 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) adalah jenis RNN khusus yang dirancang memproses data sekuensial dan mengatasi masalah *vanishing gradient* (Alsoufi dkk., 2024; Park dkk., 2025). Dalam NIDS, LSTM sangat efektif menangkap pola temporal lalu lintas jaringan, dimana urutan paket sering mengandung indikasi serangan krusial (Almuhanha & Dardouri, 2025; Baidar dkk., 2025). Gambar 2.4 mengilustrasikan struktur sel LSTM yang kompleks.



Gambar 2.4 *Arsitektur LSTM Cell dan Temporal Sequence Processing*

Varian *Bidirectional* LSTM (BiLSTM) mampu memproses urutan data dua arah, memberikan konteks deteksi yang lebih komperhesif (Park dkk., 2025). Penelitian membuktikan keunggulan LSTM dalam memodelkan ketergantungan jangka panjang menjadikannya handal untuk deteksi serangan berkarakteristik temporal seperti *low-rate* DDoS (Park dkk., 2025). Kombinasi kekuatan CNN dalam fitur spasial dan LSTM dalam fitur temporal menghasilkan model *hybrid* yang sangat andal (Baidar dkk., 2025).

2.5 Autoencoder untuk *Anomaly Detection*


Autoencoder adalah jaringan saraf *unsupervised* yang dilatih merekonstruksi inputnya sendiri melalui kompresi dan dekompresi data via *latent space* (Alsoufi dkk., 2024). Dalam IDS, autoencoder dilatih hanya dengan data normal agar model mempelajari karakteristik “normalitas” jaringan secara mendalam (Park dkk., 2025). Konsep dasarnya adalah ketika model dihadapkan pada data serangan yang aneh, ia akan gagal merekonstruksinya dengan baik sehingga menghasilkan *reconstruction error* tinggi (Korniszek & Sawicki, 2024). Hal ini menjadikan *error* tersebut indikator kuat intrusi. Pendekatan ini terbukti efektif mendeteksi serangan *zero-day* karena tidak bergantung pada pengetahuan *signature* attacks sebelumnya (Dai dkk., 2024).

Berbagai varian seperti *Stacked* Autoencoder (SAE) dan *Denoising* Autoencoder (DAE) dikembangkan untuk meningkatkan ketahanan terhadap *noise* (Devi dkk., 2025). Integrasi Autoencoder dengan arsitektur lain seperti CNN atau LSTM dalam model *hybrid* juga semakin populer karena menggabungkan ekstraksi

fitur canggih dengan deteksi anomali tanpa label (Park dkk., 2025). Meski menjanjikan, tantangan utamanya adalah menentukan *threshold* optimal untuk membedakan *error* normal dan anomali (Alsoufi dkk., 2024).

2.5.1 Arsitektur Autoencoder

Struktur Autoencoder terdiri dari dua bagian: *encoder* yang memampatkan input data ke representasi *latent*, dan *decoder* yang merekonstruksi data asli dari representasi tersebut (Alsoufi dkk., 2024). *Encoder* memaksa model mempelajari fitur esensial melalui pengurangan dimensi, menghilangkan *noise* yang tak relevan (Almuhanna & Dardouri, 2025; Park dkk., 2025). *Decoder* kemudian mencoba mengembalikan data ke bentuk aslinya sebaik mungkin (Baidar dkk., 2025). Gambar 2.5 memperlihatkan struktur simetris Autoencoder.



Gambar 2.5 Arsitektur Autoencoder dengan *Encoder-Decoder* untuk *Anomaly Detection*

Tujuan pelatihan adalah meminimalkan selisih antara input asli dan output rekonstruksi, biasanya diukur dengan *Mean Squared Error* (MSE) (Alsoufi dkk., 2024). Konsep *bottleneck* pada lapisan tengah memastikan model benar-benar mempelajari struktur data, bukan hanya menyalin input (Park dkk., 2025).

2.5.2 Reconstruction Error sebagai Indikator Anomali

Reconstruction error adalah metrik dasar dalam Autoencoder-based anomaly detection yang mengukur *discrepancy* antara input asli dan output yang direkonstruksi (Alsoufi dkk., 2024). Dalam konteks IDS, *reconstruction error*

dihitung sebagai *per-instance loss* antara *network traffic features* yang di-input dan *reconstructed features*, dimana Autoencoder yang dilatih pada normal *traffic* akan efisien merekonstruksi *normal instances* dengan *error* yang rendah namun gagal merekonstruksi *anomalous traffic* sehingga menghasilkan *error* yang tinggi (Alsoufi dkk., 2024; Park dkk., 2025). *Threshold* untuk *reconstruction error* dikalibrasi berdasarkan *validation set* menggunakan pendekatan statistik seperti $\mu + k\sigma$ dari *training error distribution* atau *percentile-based methods* (Almuhanna & Dardouri, 2025; Park dkk., 2025). Penelitian menunjukkan bahwa *reconstruction error* dapat sebagai skor anomali yang efektif untuk deteksi *zero-day* dengan *Area Under Curve* (AUC) mencapai 0.98-0.99 pada analisis ROC (Baidar et al., 2025). Tantangan yang dihadapi meliputi penentuan *threshold* yang optimal antara *true positive rate* dan *false positive rate*, serta sensitivitas model terhadap *outliers* dalam *normal training data* (Alsoufi dkk., 2024).


2.5.3 Keunggulan *Unsupervised Learning* untuk *Zero-Day Detection*

Unsupervised learning dengan Autoencoder menawarkan keunggulan signifikan untuk deteksi *zero-day attacks* yang tidak memiliki contoh berlabel dalam data latih, dimana hal ini mengurangi kebutuhan untuk data serangan berlabel yang memakan waktu dan memerlukan keahlian khusus di bidang keamanan jaringan yang mendalam (Al-Jamali dkk., 2025; Alsoufi dkk., 2024). Kemampuan model *unsupervised* untuk menggeneralisasi terhadap jenis *unseen attack* menjadikannya adaptif terhadap ancaman yang terus berkembang, dimana varian serangan baru muncul secara terus menerus (Guo, 2023). Karena tidak bergantung pada *signature databases* atau aturan tetap, sistem tidak memerlukan pembaruan yang sering dan terhindar dari celah waktu antara munculnya serangan dan tersediannya *signature* yang terdeteksi (Sridharan dkk., 2025). Penelitian empiris menunjukkan bahwa model *unsupervised* Autoencoder mampu memiliki kinerja yang sebanding dengan model *supervised* pada data *in-distribution*, sekaligus menunjukkan kemampuan yang lebih unggul dalam mendeteksi ancaman *zero-day* (Park dkk., 2025). Fleksibilitas untuk melatih ulang model dengan data lalu lintas normal yang terus diperbarui memungkinkan adaptasi terhadap perubahan

perilaku jaringan tanpa memerlukan pelabelan ulang data serangan (Baidar dkk., 2025).

2.6 Hybrid CNN-LSTM Autoencoder untuk NIDS

Hybrid CNN-LSTM Autoencoder menggabungkan tiga kekuatan utama *deep learning*: CNN untuk fitur spasial, LSTM untuk pemodelan temporal, dan Autoencoder untuk deteksi anomali tanpa pengawasan (Baidar dkk., 2025; Park dkk., 2025). Membuat integrasi ini menghasilkan sistem deteksi yang jauh lebih unggul, terutama menghadapi serangan *zero-day* (Osamor & Wellman, 2023). Dalam model ini, CNN menangkap pola lokal lalu lintas, outputnya diproses LSTM untuk urutan waktu, dan akhirnya struktur *Encoder-Decoder* merekonstruksi data untuk deteksi anomali berdasarkan *error* (Park dkk., 2025). Pendekatan ini efektif mengatasi kelemahan masing-masing model jika berdiri sendiri (Abdallah dkk., 2021). Gambar 2.6 menggambarkan arsitektur gabungan ini.



Gambar 2.6 Arsitektur *Hybrid CNN-LSTM* Autoencoder untuk *Zero-Day* Intrusion Detection

Keunggulan utama model *hybrid* ini adalah kemampuan mempelajari representasi spasial-temporal kompleks dari lalu lintas normal, yang mana hal ini krusial untuk membedakan variasi normal dan serangan (Baidar dkk., 2025). Eksperimen pada dataset uji menunjukkan model ini mencapai akurasi deteksi sangat tinggi bahkan untuk serangan yang belum pernah dilihat (Park dkk., 2025). Teknik *ensemble learning* juga dapat diterapkan untuk meningkatkan kinerja dan menekan *false positive* (Tariq dkk., 2024). Meskipun kompleksitas komputasinya lebih tinggi, akurasi yang ditawarkan menjadikannya solusi yang dapat dipertimbangkan (Akshaya & Padmavathi, 2025).

2.7 Cross-Dataset Validation

Cross-dataset validation adalah metode evaluasi yang menguji performa model IDS pada dataset berbeda dari pelatihannya (Cantone dkk., 2024). Banyak model IDS melaporkan akurasi sempurna pada satu dataset tapi gagal total di dataset lain, fenomena yang disebut “*false confidence*” (Lawall & Zöller, 2025; Xin & Xu, 2025). Pendekatan ini mensimulasikan tantangan di dunia nyata dimana pola jaringan selalu berubah antar lingkungan (Lawall & Zöller, 2025). Tanpa validasi ini, kita tidak bisa menjamin model IDS berfungsi baik saat di-*deploy* di jaringan sebenarnya (Cantone dkk., 2024). *Cross-dataset validation* memastikan model dapat berkerja dengan baik pada data baru, bukan hanya pada data yang digunakan saat pelatihan (Layeghy & Portmann, 2023).

2.7.1 Konsep *Generalization* dan *Overfitting*

Generalization adalah kemampuan model *machine learning* bekerja dengan baik pada data baru, indikator utama kecerdasan model yang sesungguhnya (Layeghy dkk., 2023; Verkerken dkk., 2021). Sebaliknya, *overfitting* terjadi saat model “*menghafal*” data latih termasuk *noise*, sehingga kinerjanya hancur pada data sumber lain (Cantone dkk., 2024). Dalam IDS, *overfitting* merupakan kondisi yang berbahaya karena dapat memberikan rasa aman palsu (*false sense of security*); model sangat baik di lingkungan laboratorium, tetapi gagal berfungsi secara efektif di kondisi sebenarnya. Penelitian menunjukkan penurunan akurasi drastis pada pengujian lintas dataset, membuktikan banyak model canggih sebenarnya *overfitting* (Cantone dkk., 2024). Faktor perbedaan distribusi data sangat mempengaruhi kemampuan generalisasi ini (Oyelakin dkk., 2023).

2.7.2 Cross-Dataset Validation Strategy

Strategi validasi ini melatih model pada source dataset dan mengujinya pada target dataset berbeda (Guida dkk., 2023). Evaluasi *multi-dataset* ini menunjukkan indikasi yang akurat terhadap kekokohan model menghadapi variasi jaringan yang bersifat heterogen (Cantone dkk., 2024). Teknik *feature selection* yang tepat juga penting untuk meningkatkan generalisasi dengan menghilangkan fitur yang terlalu spesifik (Al-kahla dkk., 2024). Untuk mengatasi tantangan pergeseran distribusi

data (*distribution shift*) antar dataset, strategi validasi ini dapat diperkuat dengan teknik *domain adaptation* atau *fine-tuning* ringan pada dataset target. Liao dkk. (2024) menunjukkan bahwa *Few-Shot Domain Adaptation* mampu menjembatani kesenjangan distribusi antar dataset (*data drift*) secara efektif. Dengan memberikan sedikit sampel data normal dari lingkungan baru (*target domain*), model dapat "mengkalibrasi" ulang pemahamannya tentang pola normal tanpa perlu dilatih ulang sepenuhnya dari awal (Yue dkk., 2023). Pendekatan ini bertujuan untuk membangun model yang memahami esensi serangan, bukan hanya karakteristik dataset.

2.8 Dataset

Dalam pengembangan IDS berbasis *machine learning*, dataset adalah fondasi utama yang menentukan kemampuan model dalam memahami *signature attacks* (Cantone dkk., 2024). Kualitas serta tingkat realisme dataset sangat berpengaruh terhadap efektivitas model dalam mengenali serangan di lingkungan yang sebenarnya (Ghurab dkk., 2021). Oleh karena itu, dataset modern harus mencakup skenario serangan terkini dan trafik jaringan yang realistis. Dua dataset standar *de-facto* saat ini adalah CIC-IDS2017 dan CSE-CIC-IDS2018 karena ukuran dan keragaman serangannya (Sharafaldin dkk., 2018). Namun, setiap dataset punya bias dan error yang bisa menyesatkan model jika tidak ditangani benar (Liu dkk., 2022). Oleh karena itu, strategi *preprocessing* dan *cross-validation* sangat penting dalam pengembangan IDS (Cantone dkk., 2024).

2.8.1 CIC-IDS2017

Tantangan utama dalam riset IDS saat ini adalah mencari dataset yang benar-benar realistis. Hal ini sangat penting agar model tidak hanya menunjukkan performa tinggi secara teoretis, tetapi juga efektif di lingkungan yang sebenarnya. Sebagai rujukan utama, CIC-IDS2017 menyediakan trafik jaringan selama lima hari dengan total 2,8 juta *instances* yang mencakup serangan modern seperti DDoS dan *Infiltration* (Canadian Institute for Cybersecurity, 2017; Oyelakin dkk., 2023; Sharafaldin dkk., 2018). Namun, beberapa studi mengidentifikasi adanya isu signifikan pada dataset tersebut, di antaranya temuan galat (*error*) pada 78 fitur

hasil ekstraksi serta masalah ketidakseimbangan kelas (*class imbalance*) yang sangat ekstrem antara trafik *benign* dan serangan (Gopalan dkk., 2021; Rosay dkk., 2022). Kondisi ini berdampak buruk pada performa model, terutama pada pengujian lintas dataset, di mana akurasi sering kali turun drastis akibat anomali data tersebut (Barkah dkk., 2023; Cantone dkk., 2024). Oleh karena itu, solusi yang banyak direkomendasikan adalah penerapan praproses (*preprocessing*) yang ketat disertai validasi ulang fitur agar hasil klasifikasi lebih valid dan memiliki generalisasi yang lebih kuat

2.8.2 CSE-CIC-IDS2018

Sebagai pengembangan dari versi sebelumnya, dataset CSE-CIC-IDS2018 berkembang dari kolaborasi antara peneliti dengan *Communications Security Establishment* (CSE) dan *Amazon Web Services* (AWS), yang mana infrastruktur komputasi *cloud* ini memungkinkan perekaman data skala besar baik dalam format PCAP mentah maupun data yang sudah terproses (Canadian Institute for Cybersecurity & Communications Security Establishment, 2018; Sharafaldin dkk., 2018). Skala masif ini dirancang khusus untuk mengatasi keterbatasan pendahulunya, namun tantangan yang baru justru muncul dalam bentuk fenomena “*false confidence*” di kalangan peneliti (Karatas dkk., 2020). Walaupun model *deep learning* sering menunjukkan akurasi internal yang sangat tinggi pada dataset ini, tetapi kinerjanya kadang menurun secara signifikan akibat pergeseran distribusi data saat diuji lintas dataset. Hal ini menunjukkan bahwa model terlalu menyesuaikan diri dengan bias spesifik dataset daripada benar-benar memahami esensi serangan (Cantone dkk., 2024). Temuan ini menegaskan bahwa kuantitas data semata tidak menjamin terciptanya model yang unggul terhadap variasi jaringan yang sebenarnya, sehingga strategi *cross-validation* yang lebih mendalam menjadi sangat diperlukan (Cantone dkk., 2024).

2.8.3 Feature Alignment dan Cross-Dataset Strategy

Dalam konteks *cross-validation* lintas dataset, strategi *feature alignment* menjadi elemen krusial untuk mengatasi perbedaan dimensi dan definisi fitur yang sering muncul antar lingkungan jaringan yang berbeda (Xin & Xu, 2025). Masalah

yang tidak cocok ini sering kali diperparah oleh fenomena pergeseran distribusi data (*distribution shift*), yang mana hal ini dapat menurunkan performa model IDS secara signifikan jika dirancang untuk dapat beradaptasi terhadap perubahan lingkungan (Cantone dkk., 2024). Sebagai solusi untuk mengatasi hambatan struktural tersebut, model MFEI-IDS yang diusulkan oleh Mao dkk. (2025) menggunakan kombinasi *Fully Convolutional Networks* dan *Transformer* untuk menyamakan representasi fitur secara hierarkis. Selain itu, penerapan seleksi fitur berbasis mRMR (minimum Redundancy Maximum Relevance) juga sangat penting untuk memangkas fitur yang rentan terhadap *noise*, yang mana langkah ini secara signifikan meningkatkan ketahanan model terhadap variabilitas data baru sekaligus menjaga stabilitas deteksi pada skenario operasional jaringan yang sebenarnya (Cantone dkk., 2024).

2.9 Metrik Evaluasi

Evaluasi kinerja IDS tidak bisa hanya mengandalkan akurasi, melainkan juga perlu serangkaian metrik komprehensif untuk memahami perilaku model secara penuh (Salih & Abdulazeez, 2021). Mengingat sifat data keamanan yang sangat tidak seimbang dimana serangan adalah kejadian yang langka, metrik seperti *Precision*, *Recall*, dan *F1-Score* jauh lebih relevan (Le dkk., 2024). Selain itu, untuk sistem anomaly detection, analisis kurva ROC dan nilai AUC menjadi standar emas mengukur kemampuan separasi model (Bai & Fossaceca, 2024). *False Positive Rate* juga metrik operasional yang krusial karena berkaitan langsung dengan kelelahan analis keamanan (*alert fatigue*) (Mohale & Obagbuwa, 2025).

2.9.1 Classification Metrics

Metrik klasifikasi dasar diturunkan dari *confusion matrix* yang berfungsi untuk memetakan prediksi benar dan salah. *Precision* mengukur keandalan prediksi serangan, sedangkan *Recall* mengukur kemampuan mendeteksi seluruh serangan ada (Salih & Abdulazeez, 2021). *F1-Score* berfungsi memberikan keseimbangan keduanya, sangat penting untuk menghindari *false alarm* tanpa melewatkan serangan (Agarwal dkk., 2021). *Matthews Correlation Coefficient* (MCC) dianggap metrik yang lebih representatif untuk evaluasi pada dataset yang tidak seimbang

karena mempertimbangkan semua aspek *confusion matrix* (Cantone dkk., 2024). Penggunaan metrik ini bersamaan memberikan gambaran lengkap kekuatan model IDS.

2.9.2 ROC Curve dan AUC

Kurva ROC menggambarkan *trade-off* antara *True Positive Rate* dan *False Positive Rate* pada berbagai titik ambang batas (*threshold*) operasi (Bai & Fossaceca, 2024). Sebagai metrik evaluasi, *Area Under Curve* (AUC) merangkum kinerja model tersebut dalam satu nilai tunggal. Keunggulan AUC terletak pada stabilitasnya terhadap ketimpangan kelas data (*class imbalance*), sehingga mampu membedakan aktivitas normal dan serangan dengan baik (Xin & Xu, 2025). Pada skenario deteksi anomali tanpa label (*unsupervised*), pengembangan varian seperti EM-AUC memungkinkan evaluasi tetap objektif meskipun tanpa tersedia *ground truth* yang lengkap (Bai & Fossaceca, 2024).

2.9.3 False Positive Rate (FPR)

Tingkat *False Positive Rate* (FPR) merupakan salah satu tantangan yang paling signifikan dalam operasional *Security Operations Center* (SOC). Akumulasi peringatan palsu yang tinggi dapat menyebabkan *alert fatigue*, yang berisiko membuat analis melewatkan ancaman yang valid (Mohale & Obagbuwa, 2025). Pada jaringan IoT, menjaga FPR tetap rendah menjadi prioritas utama untuk mencegah gangguan pada fungsi perangkat (Amrullah, 2025). Penelitian Mohale & Obagbuwa (2025) menunjukkan bahwa penggunaan algoritma XGBoost mampu menekan nilai FPR hingga 0,07. Selain itu, penerapan algoritma *Explainable AI* (XAI) seperti SHAP dan kalibrasi *Platt scaling* membantu analis dalam memverifikasi pemicu deteksi secara lebih akurat.

2.9.4 Generalization Metrics


Metrik generalisasi merepresentasikan kemampuan suatu model untuk beroperasi secara efektif pada data yang belum pernah dilihat (*unseen data*) (Park dkk., 2025). Hal ini sangat krusial untuk memastikan bahwa sistem IDS siap menghadapi variasi serangan sebenarnya, bukan sekadar memberikan performa

tinggi pada dataset uji coba (Cantone dkk., 2024). Penurunan performa yang drastis lintas dataset (*cross-dataset*) menunjukkan adanya masalah *overfitting*, sehingga kemampuan generalisasi menjadi indikator utama dalam kesiapan implementasi model (Cantone dkk., 2024).

BAB III METODOLOGI PENELITIAN

3.1 Desain Penelitian

Penelitian ini menggunakan *Design Research Methodology* (DRM) sebagai pendekatan sistematis untuk mengidentifikasi masalah, mengembangkan solusi, dan mengevaluasi efektivitasnya (Blessing & Chakrabarti, 2009). DRM dipilih karena menyediakan kerangka desain yang mendukung pengembangan artefak teknis seperti model deteksi intrusi, dengan empat tahapan yang bersifat iteratif dimana hasil evaluasi dapat memicu perbaikan desain atau penyesuaian metode. Proses iterasi ini terjadi ketika hasil Studi Deskriptif II menunjukkan performa yang belum optimal, sehingga dapat dilakukan refinement pada tahap Studi Preskriptif seperti *tuning hyperparameter* atau penyesuaian *threshold* deteksi. Metodologi ini memastikan penelitian berjalan terstruktur, khususnya pada pengembangan model *Hybrid CNN-LSTM Autoencoder* untuk deteksi *zero-day attack* dengan pendekatan *unsupervised learning*. Gambar 3.1 menunjukkan alur DRM yang diterapkan.



Gambar 3.1 *Design Research Methodology* (DRM)

3.1.1 Klarifikasi Penelitian

Tahap klarifikasi penelitian dilakukan untuk mengidentifikasi inti permasalahan melalui studi literatur yang komprehensif terhadap berbagai referensi ilmiah terkait keamanan siber, deteksi serangan *zero-day*, algoritma *deep learning*, dan teknik *unsupervised learning*. Kajian literatur mencakup arsitektur CNN untuk ekstraksi fitur spasial, LSTM untuk pemodelan temporal, dan Autoencoder untuk deteksi anomali berbasis reconstruction error. Selain itu, dipelajari juga metode evaluasi performa model seperti akurasi, presisi, recall, *F1-score*, dan AUC-ROC sebagai acuan penilaian keberhasilan (Park dkk., 2025). Analisis *research gap* pada tahap ini menemukan bahwa mayoritas penelitian IDS sebelumnya hanya melakukan evaluasi pada *single dataset* tanpa memvalidasi kemampuan generalisasi model terhadap dataset berbeda, yang menjadi fokus utama penelitian ini.

Berdasarkan analisis gap tersebut, penelitian ini merumuskan dua pertanyaan penelitian utama: (1) Bagaimana performa model *Hybrid CNN-LSTM Autoencoder* dalam mendeteksi serangan siber pada dataset CIC-IDS2017 dibandingkan dengan *baseline methods*? (2) Bagaimana kemampuan generalisasi model *Hybrid CNN-LSTM Autoencoder* dalam mendeteksi serangan *zero-day* melalui *cross-dataset validation* menggunakan dataset CSE-CIC-IDS2018? Untuk menjawab pertanyaan tersebut, ditetapkan kriteria keberhasilan penelitian yaitu model harus mencapai *F1-score* minimal 90% pada dataset *baseline* dan *generalization gap* tidak boleh melebihi 15% untuk memastikan model dapat beradaptasi dengan data baru.

3.1.2 Studi Deskriptif I

Tahap ini berfokus pada analisis kebutuhan sistem dan karakteristik data yang akan digunakan. Berdasarkan tinjauan literatur, teridentifikasi beberapa keterbatasan metode yang sudah ada seperti ketergantungan pada *supervised learning* yang memerlukan label serangan terbaru, evaluasi *single-dataset* yang tidak membuktikan generalisasi model, dan kompleksitas arsitektur *ensemble* yang berdampak pada beban komputasi yang tinggi. Keterbatasan ini menjadi dasar pemilihan pendekatan *unsupervised learning* dengan *cross-dataset validation* pada

penelitian ini. Analisis kebutuhan mencakup identifikasi spesifikasi teknis seperti *environment* dengan dukungan GPU, *framework* TensorFlow, serta alat *preprocessing* seperti Pandas dan NumPy (Singh & Jang, 2022). Analisis data dilakukan terhadap dua dataset publik, yaitu CIC-IDS2017 dengan 2,7 juta records dan lebih dari 80 fitur, serta CSE-CIC-IDS2018 dengan 16,2 juta records dan 80 fitur. Dataset pertama mencakup trafik normal dan berbagai serangan seperti DoS/DDoS, Web Attacks, Botnet, dan Heartbleed, sedangkan dataset kedua memiliki serangan lebih kompleks. Hasil analisis menunjukkan perlunya *feature alignment* antara kedua dataset untuk memungkinkan *cross-dataset validation* sebagai kontribusi utama pada penelitian ini.

3.1.3 Studi Preskriptif

Studi preskriptif merupakan tahap inti yang mencakup seluruh proses teknis pengembangan model *Hybrid CNN-LSTM Autoencoder* untuk deteksi anomali *zero-day*. Tahapan ini terdiri dari beberapa subbagian yang saling berkaitan, mulai dari persiapan *environment*, analisis data awal, *preprocessing*, implementasi arsitektur model, *training* dan optimisasi, hingga validasi lintas dataset. Secara keseluruhan, tahapan ini merealisasikan pendekatan solusi yang telah dirumuskan sebelumnya melalui serangkaian eksperimen sistematis.

3.1.3.1 Persiapan *Environment*

Tahap persiapan dimulai dengan instalasi Python 3.8+ dan persiapan *virtual environment* menggunakan *uv* atau *venv*. *Library dependencies* yang digunakan meliputi TensorFlow 2.x, NumPy, Pandas, Scikit-learn, Matplotlib, dan Seaborn untuk mendukung proses *training* dan analisis data. Konfigurasi GPU driver CUDA dilakukan untuk mempercepat proses *training* model. Dataset CIC-IDS2017 dan CSE-CIC-IDS2018 diunduh dari situs resmi CIC dan diekstraksi ke dalam struktur direktori yang terorganisir (Park dkk., 2025).


3.1.3.2 *Exploratory Data Analysis*

Exploratory data analysis (EDA) dilakukan untuk memahami karakteristik dataset melalui inspeksi struktur data, identifikasi *missing values* dan *infinite*

values, serta visualisasi distribusi fitur menggunakan *histogram* dan *boxplot*. Analisis korelasi antar fitur dilakukan menggunakan *heatmap correlation matrix* untuk mengidentifikasi fitur yang berkorelasi tinggi. Berdasarkan hasil EDA, dilakukan *preprocessing* yang mencakup *handling missing values*, *handling infinite values*, *feature alignment* antara kedua dataset, dan *data cleaning* untuk menghapus duplikasi serta outlier ekstrem. Khusus data *training*, dilakukan *filtering* untuk mengambil hanya data dengan label "BENIGN" sesuai paradigma *unsupervised learning* (Almuhanna & Dardouri, 2025).

3.1.3.3 Preprocessing dan Feature Engineering

Feature engineering mencakup *encoding categorical features*, normalisasi fitur numerik menggunakan MinMaxScaler atau StandardScaler, dan *reshaping data* menjadi format 3D (*samples*, *timesteps*, *features*) sesuai input LSTM layer. Data split dilakukan dengan proporsi 70% *training*, 15% *validation*, dan 15% *testing* pada CIC-IDS2017, sedangkan seluruh CSE-CIC-IDS2018 digunakan sebagai test set untuk *cross-dataset validation* (Singh & Jang, 2022). Alur lengkap pemrosesan data, dari data mentah hingga menjadi input siap latih, diilustrasikan pada Gambar 3.2.




Gambar 3.2 Alur *Preprocessing* dan Pembentukan Data *Time-Series*

3.1.3.4 Implementasi Arsitektur Model

Implementasi arsitektur *Hybrid CNN-LSTM Autoencoder* dilakukan menggunakan Keras API dengan struktur *encoder* yang terdiri dari *Conv1D layers* untuk ekstraksi fitur spasial diikuti *LSTM layers* untuk pemodelan temporal, *bottleneck layer* sebagai *latent representation*, dan *decoder* yang merupakan *mirror*

dari *encoder* untuk rekonstruksi input. Arsitektur ini dirancang khusus untuk menangkap pola spasial dan temporal dalam *network traffic* data secara simultan. Detail arsitektur model beserta dimensi data pada setiap lapisannya ditampilkan secara rinci pada Gambar 3.3.



Gambar 3.3 Arsitektur *Hybrid CNN-LSTM* Autoencoder yang Diusulkan

3.1.3.5 Training dan Optimisasi Model


Training model menggunakan hanya data normal dengan *loss function Mean Squared Error* (MSE) untuk mengukur *reconstruction error* antara input asli dan output rekonstruksi, yang diformulasikan pada Persamaan (1).

$$MSE = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i)^2 \quad (1)$$

Proses *training* menggunakan *optimizer* Adam dengan *learning rate* 0.001, *batch size* 128-256, dan *early stopping* jika *validation loss* tidak menurun selama 10 *epoch* berturut-turut. Pengawasan dilakukan terhadap *training loss* dan *validation loss* untuk mendeteksi *overfitting* atau *underfitting*. Evaluasi pada test set CIC-IDS2017 dilakukan dengan menghitung *reconstruction error*, menentukan *threshold* berdasarkan 95th atau 99th persentil, dan menghitung metrik evaluasi seperti akurasi, presisi, *recall*, *F1-score*, dan AUC-ROC.

3.1.3.6 Cross-Dataset Validation

Cross-dataset validation dilakukan dengan menggunakan model yang dilatih pada CIC-IDS2017 untuk memprediksi sampel dari CSE-CIC-IDS2018 dalam dua skenario: *zero-shot* (tanpa retraining) dan *few-shot adaptation* (*fine-tuning* dengan sampel terbatas). *Reconstruction error* dihitung untuk semua sampel, *threshold* yang sama dari *training* digunakan untuk klasifikasi, dan metrik evaluasi dihitung untuk mengukur performa pada dataset berbeda. Analisis *generalization gap* dilakukan dengan membandingkan performa pada kedua dataset, serta analisis *per-attack-type performance* untuk melihat jenis serangan yang paling sulit dideteksi. Skema validasi lintas dataset ini, yang menjadi metode utama untuk menguji kemampuan generalisasi dan deteksi serangan *zero-day*, dapat dilihat secara visual pada Gambar 3.4.



Gambar 3.4 Skema Eksperimen Validasi Lintas Dataset (*Cross-Dataset Validation*)

Dokumentasi hasil mencakup pembuatan visualisasi *ROC curve*, *confusion matrix*, dan *reconstruction error distribution plot*, serta tabel hasil evaluasi yang membandingkan berbagai metrik.

3.1.4 Studi Deskriptif II

Tahap Studi Deskriptif II dilakukan untuk mengevaluasi performa model secara mendalam dan menganalisis hasil eksperimen. Evaluasi dilakukan dalam beberapa aspek untuk memvalidasi kemampuan model dari berbagai sudut pandang, yang mencakup analisis performa klasifikasi, kemampuan generalisasi, pengujian signifikansi statistik, dan optimisasi *threshold* deteksi.

3.1.4.1 Analisis Performa Model

Analisis performa model dilakukan dengan mengevaluasi kemampuan *Hybrid CNN-LSTM Autoencoder* dalam mendeteksi anomali. Evaluasi *baseline* pada CIC-IDS2017 menggunakan metrik akurasi, presisi, *recall*, dan *F1-score* yang dihitung dari *confusion matrix*. Nilai presisi tinggi menunjukkan alarm model dapat dipercaya dengan *false alarm minimal*, sedangkan *recall* tinggi berarti model mampu mendeteksi mayoritas serangan (Park dkk., 2025). Analisis distribusi error rekonstruksi dilakukan untuk melihat pemisahan antara data normal dan anomali, dimana idealnya kedua distribusi harus terpisah jauh. Analisis per tipe serangan juga dilakukan untuk mengidentifikasi kelebihan dan kekurangan model dalam mendeteksi berbagai jenis serangan.

3.1.4.2 Analisis Generalisasi


Analisis generalisasi merupakan aspek yang penting untuk mengukur kemampuan model pada dataset yang berbeda dari *dataset training*. *Generalization gap* dihitung dengan mencari selisih antara performa di dataset CIC-IDS2017 (*in-distribution*) dan performa di dataset CSE-CIC-IDS2018 (*out-of-distribution*), yang diformulasikan pada Persamaan (2).

$$\text{Gap}_{\text{metric}} = M_{\text{CIC}} - M_{\text{CSE}} \quad (2)$$

Dimana M_{CIC} adalah nilai metrik di CIC-IDS2017 dan M_{CSE} adalah nilai metrik di CSE-CIC-IDS2018. Gap yang kecil menunjukkan model memiliki kemampuan generalisasi yang baik dan tidak *overfitting*, sedangkan gap besar mengindikasikan model hanya efektif pada data *training* (Singh & Jang, 2022). Analisis kualitatif dilakukan untuk mengidentifikasi faktor penyebab penurunan performa, seperti perbedaan distribusi fitur atau keberadaan serangan baru seperti Heartbleed di dataset CSE-CIC-IDS2018.

3.1.4.3 Pengujian Statistik

Pengujian statistik dilakukan untuk memastikan perbedaan performa yang diamati signifikan secara statistik dan bukan karena faktor kebetulan. Metode McNemar's test digunakan untuk membandingkan performa model pada kedua dataset dengan membuat tabel kontingensi dari prediksi benar dan salah (Halbouni et al., 2022). Hipotesis null menyatakan tidak ada perbedaan signifikan antara performa model di kedua dataset, sedangkan hipotesis alternatif menyatakan ada perbedaan signifikan. Level signifikansi ditetapkan pada α 0.05, dimana p -value kurang dari 0.05 mengindikasikan penolakan hipotesis null dan perbedaan yang signifikan secara statistik (Park et al., 2025). Ilustrasi bagaimana *threshold* memisahkan distribusi error trafik normal dan serangan ditunjukkan pada Gambar 3.5.



Gambar 3.5 Ilustrasi Penentuan *Threshold* Deteksi Berdasarkan *Distribusi Error*.

3.1.4.4 Analisis *Threshold*

Analisis *threshold* bertujuan menentukan nilai batas *error* optimal untuk memisahkan data normal dan anomali. *Threshold* dipilih berdasarkan distribusi *error* di data validasi normal menggunakan nilai persentil tertentu seperti 95th atau 99th persentil. Pemilihan ini melibatkan *trade-off* dimana *threshold* rendah (95th) menghasilkan TPR tinggi namun FPR juga meningkat, sedangkan *threshold* tinggi (99th) menurunkan FPR namun juga menurunkan TPR (Singh & Jang, 2022). Optimisasi dilakukan dengan mencoba berbagai nilai *threshold* dan memilih yang menghasilkan *F1-score* maksimal seperti pada Persamaan (3).

$$\theta_{optimal} = \arg \max_{\theta} F1(\theta) \quad (3)$$

Alternatif lain menggunakan Youden's Index untuk memaksimalkan selisih TPR dan FPR, atau menyesuaikan dengan kebijakan organisasi seperti membatasi FPR dibawah 1% untuk meminimalkan false alarm.

3.2 Instrumen Penelitian

Instrumen penelitian merupakan alat ukur yang krusial yang digunakan untuk mengumpulkan data serta mengevaluasi hasil eksperimen dalam penelitian ini, dimana pemilihan instrumen yang tepat sangat penting untuk memastikan validitas dan reliabilitas hasil yang didapatkan. Dalam konteks penelitian deteksi intrusi berbasis *deep learning* yang dilakukan, instrumen penelitian mencakup berbagai metrik evaluasi kuantitatif yang mana metrik-metrik ini telah divalidasi secara luas dalam domain *machine learning*. Instrumen evaluasi ini dirancang untuk mengukur tiga aspek utama yaitu performa klasifikasi model, kemampuan deteksi anomali, serta kemampuan generalisasi terhadap data baru yang belum pernah dilihat sebelumnya.

Untuk mengukur kemampuan model dalam melakukan klasifikasi antara trafik normal dan anomali, digunakan beberapa metrik standar. Metrik pertama adalah akurasi yang mengukur proporsi prediksi benar dari total prediksi, yang mana formulanya dapat dilihat pada Persamaan (4) dimana TP adalah *True Positive*, TN adalah *True Negative*, FP adalah *False Positive*, dan FN adalah *False Negative*.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (4)$$

Selain itu, digunakan juga metrik presisi yang mengukur proporsi prediksi positif yang benar-benar positif. Hal ini penting untuk mengukur tingkat kepercayaan terhadap *alarm* yang dihasilkan sistem agar *alarm* yang palsu tidak terlalu banyak (Park et al., 2025). Formula presisi ditunjukkan pada Persamaan (5).

$$Precision = \frac{TP}{TP + FP} \quad (5)$$

Metrik *recall* atau *sensitivity* juga digunakan untuk mengukur proporsi sampel positif yang berhasil terdeteksi, dimana ini sangat krusial dalam konteks IDS karena kegagalan mendeteksi serangan dapat berakibat fatal bagi keamanan jaringan. Formula *recall* ditunjukkan pada Persamaan (3).

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

F1-score digunakan sebagai harmonic mean antara *presisi* dan *recall*, yang mana metrik ini memberikan keseimbangan antara kedua aspek tersebut terutama pada kondisi data yang imbalanced atau tidak seimbang. Formula *F1-score* ditunjukkan pada Persamaan (6).

$$F1-score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (6)$$

Selanjutnya, instrumen evaluasi *anomaly detection* berfokus pada kemampuan model untuk membedakan pola normal dan anomali berdasarkan *reconstruction error*. Metrik utama yang digunakan adalah AUC-ROC yang mengukur kemampuan model dalam memisahkan dua kelas pada berbagai *threshold*. ROC curve sendiri dibuat dengan memplot *True Positive Rate* (TPR) terhadap *False Positive Rate* (FPR) pada berbagai *threshold reconstruction error*, yang mana ini memberikan visualisasi mengenai *trade-off* antara *detection rate* dan *false alarm rate* (Singh & Jang, 2022). Selain itu, *False Positive Rate* (FPR) juga dihitung untuk mengukur proporsi trafik normal yang salah diklasifikasikan sebagai anomali menggunakan Persamaan (7) berikut.

$$FPR = \frac{FP}{FP + TN} \quad (7)$$

Terakhir, instrumen evaluasi *generalization* digunakan untuk mengukur kemampuan model dalam mendeteksi serangan pada dataset yang berbeda dari dataset *training*. Metrik krusial yang digunakan adalah *generalization gap* yang dihitung sebagai selisih performa antara evaluasi pada test set dataset yang sama (*in-distribution*) dan evaluasi pada dataset yang berbeda (*out-of-distribution*) seperti yang ditunjukkan pada Persamaan (8).

$$\text{Generalization Gap} = P_{in} - P_{out} \quad (8)$$

Dimana *generalization gap* yang kecil menunjukkan bahwa model memiliki kemampuan generalisasi yang baik dan tidak overfitting pada karakteristik spesifik dataset training (Park dkk., 2025). *Statistical significance testing* menggunakan metode seperti McNemar's test juga diterapkan untuk memastikan perbedaan performa yang diamati bukan terjadi karena kebetulan.

3.3 Alat dan Bahan Penelitian

3.3.1 Alat Penelitian

Alat penelitian ini mencakup perangkat keras dan lunak untuk mendukung komputasi intensif *Deep Learning*. Dari sisi *hardware*, dibutuhkan komputer dengan GPU (*Graphics Processing Unit*) berspesifikasi tinggi guna mempercepat proses pelatihan model. Rincian spesifikasi perangkat keras disajikan pada Tabel 3.1, dimana penggunaan platform *cloud* seperti Google Colab Pro juga dimungkinkan sebagai alternatif lingkungan komputasi yang fleksibel.

Tabel 3.1 Spesifikasi *Hardware* Penelitian

Komponen	Spesifikasi	Fungsi
GPU	NVIDIA RTX 4060 8GB VRAM dengan CUDA support	Mempercepat proses training model neural network
RAM	32 GB DDR4	Menangani dataset berukuran besar dan operasi preprocessing

Storage	SSD 256 GB	Menyimpan dataset, model checkpoint, dan hasil eksperimen
Processor	AMD Ryzen 5 4600G (6 cores / 12 threads)	Mendukung komputasi paralel untuk preprocessing data
OS	Windows 11	Kompatibilitas dengan tools deep learning

Pada aspek *software*, Visual Studio Code digunakan sebagai *Integrated Development Environment* (IDE) utama yang menjalankan *kernel* Jupyter secara lokal untuk memaksimalkan performa GPU RTX 4060. Penggunaan layanan *cloud* seperti Google Colab disiapkan sebagai lingkungan komputasi alternatif untuk validasi silang. Bahasa Python v3.8+ dengan *framework* TensorFlow 2.x dipilih untuk membangun arsitektur *Hybrid CNN-LSTM Autoencoder*. Tabel 3.2 merincikan seluruh perangkat lunak yang digunakan, dimana kombinasi alat *open-source* ini menjamin aksesibilitas dan kemudahan reproduksi penelitian.

Tabel 3.2 *Software dan Library yang Digunakan*

Kategori	Software/Library	Versi	Fungsi
IDE & Cloud Compute	VS Code (Local Jupyter) / Google Colab	Latest	Lingkungan pengembangan utama & eksekusi komputasi
Bahasa Pemrograman	Python	3.8+	Bahasa pemrograman utama untuk implementasi
Deep Learning Framework	TensorFlow	2.x	Engine untuk membangun dan melatih model CNN-LSTM
Numerical Computing	NumPy	1.21+	Operasi numerik dan manipulasi array
Data Manipulation	Pandas	1.3+	Manipulasi data tabular dan preprocessing

Machine Learning	Scikit-learn	1.0+	Preprocessing, feature scaling, dan evaluasi metrik
Visualization	Matplotlib, Seaborn	3.5+, 0.11+	Visualisasi hasil eksperimen dan analisis data
Version Control	Git, GitHub	Latest	Manajemen kode dan kolaborasi
GPU Support	NVIDIA CUDA (Local/Cloud)	12.x	Akselerasi komputasi GPU RTX 4060

3.3.2 Bahan Penelitian

Bahan utama penelitian ini adalah dataset *benchmark* CIC-IDS2017 dan CSE-CIC-IDS2018 dari *Canadian Institute for Cybersecurity*. Dataset CIC-IDS2017 mencakup 2,8 juta *network flows* selama lima hari kerja, dimana hari Senin hanya berisi trafik normal. Karakteristik dataset ini, sebagaimana dirinci pada Tabel 3.3, sangat representatif karena memuat berbagai serangan modern.

Tabel 3.3 Karakteristik Dataset CIC-IDS2017

Karakteristik	Deskripsi
Sumber	Canadian Institute for Cybersecurity (CIC)
Durasi Pengumpulan	5 hari kerja (Senin - Jumat)
Jumlah Total Records	~2,8 juta network flows
Jumlah Fitur	Lebih dari 80 fitur statistik berbasis flow
Format File	CSV
Tools Ekstraksi	CICFlowMeter
Trafik Normal	Hari Senin (Hanya berisi trafik benign)
Jenis Serangan	Brute Force (FTP-Patator, SSH-Patator) DoS/DDoS (DoS Hulk, DDoS, DoS GoldenEye, DoS Slowloris, DoS Slowhttptest)

	Web Attacks (SQL Injection, XSS, Brute Force) Infiltration Botnet Port Scan Heartbleed
Link Download	https://www.unb.ca/cic/datasets/ids-2017.html

Dataset CSE-CIC-IDS2018 digunakan sebagai set pengujian eksternal, yang mana dataset ini memuat 16 juta *flows* dengan serangan kompleks seperti *Heartbleed*. Penggunaannya bertujuan mensimulasikan skenario serangan *zero-day* melalui validasi lintas dataset. Tabel 3.4 memperlihatkan detail karakteristiknya, dimana struktur fiturnya memiliki kesamaan dengan dataset 2017 sehingga memudahkan proses penyelarasan data.

Tabel 3.4 Karakteristik Dataset CSE-CIC-IDS2018

Karakteristik	Deskripsi
Sumber	Canadian Institute for Cybersecurity (CIC) & CSE Canada
Durasi Pengumpulan	10 hari
Jumlah Total Records	~16,2 juta network flows
Jumlah Fitur	80 fitur statistik berbasis flow
Format File	CSV
Tools Ekstraksi	CICFlowMeter
Fungsi dalam Penelitian	<i>Test set</i> untuk <i>cross-dataset validation (zero-day simulation)</i>
Jenis Serangan	Brute-Force (FTP, SSH, Web) DoS/DDoS attacks (berbagai variasi protokol) Heartbleed vulnerability exploitation Web Attacks Infiltration scenario (APT simulation) Botnet activities

Keunggulan	Mencakup serangan yang tidak ada di CIC-IDS2017 (Heartbleed)
Link Download	https://www.unb.ca/cic/datasets/ids-2018.html

Kedua dataset ini dipilih karena dokumentasinya lengkap dan merupakan standar evaluasi IDS saat ini. Kompabilitas antar dataset mempermudah penyelarasan fitur (*feature alignment*) yang penting untuk menguji kemampuan model dalam mendeteksi serangan baru.

DAFTAR PUSTAKA

- Abdallah, M., An Le Khac, N., Jahromi, H., & Delia Jurcut, A. (2021). A Hybrid CNN-LSTM Based Approach for Anomaly Detection Systems in SDNs. *ACM International Conference Proceeding Series*.
<https://doi.org/10.1145/3465481.3469190>;PAGE:STRING:ARTICLE/CHAPTER
- Achbarou, O., Datsi, T., Bourkhou, O., & El kiram, A. M. (2025). Enhanced intrusion detection system using feature selection and hybrid learning models for high performance and efficiency in an IOT environment. *Journal of Engineering Research*. <https://doi.org/10.1016/J.JER.2025.10.016>
- Agarwal, A., Sharma, P., Alshehri, M., Mohamed, A., & Alfarraj, O. (2021). Classification model for accuracy and intrusion detection using machine learning approach. *PeerJ Computer Science*, 7, e437.
<https://doi.org/10.7717/PEERJ-CS.437>
- Ahmed, U., Nazir, M., Sarwar, A., Ali, T., Aggoune, E. H. M., Shahzad, T., & Khan, M. A. (2025). Signature-based intrusion detection using machine learning and deep learning approaches empowered with fuzzy clustering. *Scientific Reports 2025 15:1*, 15(1), 1726-. <https://doi.org/10.1038/s41598-025-85866-7>
- Akshaya, S., & Padmavathi. (2025). ENHANCING CYBER DEFENSE AGAINST ZERO-DAY ATTACKS USING ENSEMBLE NEURAL NETWORKS. *International Journal of Computer Networks and Communications*, 17(4), 131–132. <https://doi.org/10.5121/ijcnc.2025.17408>
- Al-Jamali, N., Zaroor, A. R., & Al-Raweshidy, H. S. (2025). An Effective Technique of Zero-Day Attack Detection in the Internet of Things Network Based on the Conventional Spike Neural Network Learning Method. *IET Networks*, 14(1), e70019.
<https://doi.org/10.1049/NTW2.70019>;WEBSITE:WEBSITE:IETRESEARCH;WGROU:STRING:PUBLICATION
- Aljanabi, M., Ismail, M. A., & Ali, A. H. (2021). Intrusion Detection Systems, Issues, Challenges, and Needs. *International Journal of Computational Intelligence Systems*, 14(1), 560–571.
<https://doi.org/10.2991/IJCIS.D.210105.001>

- Al-kahla, L., Hussein, M. K., & Alqassab, A. (2024). Feature Selection Techniques in Intrusion Detection: A Comprehensive Review. *Iraqi Journal for Computers and Informatics*, 50(1), 46–53. <https://doi.org/10.25195/IJCI.V50I1.462>
- Almuhanna, R., & Dardouri, S. (2025). A deep learning/machine learning approach for anomaly based network intrusion detection. *Frontiers in Artificial Intelligence*, 8, 1625891. <https://doi.org/10.3389/FRAI.2025.1625891>
- Alsoufi, M. A., Siraj, M. M., Ghaleb, F. A., Al-Razgan, M., Al-Asaly, M. S., Alfakih, T., & Saeed, F. (2024). Anomaly-Based Intrusion Detection Model Using Deep Learning for IoT Networks. *CMES - Computer Modeling in Engineering and Sciences*, 141(1), 823–845. <https://doi.org/10.32604/CMES.2024.052112>
- Amrullah, A. (2025). A Review and Comparative Analysis of Intrusion Detection Systems for Edge Networks in IoT | Intellithings Journal. *Intellithings Journal*. <https://e-jurnal.unisda.ac.id/index.php/intellithings/article/view/8859>
- Bai, K., & Fossaceca, J. (2024). EM-AUC: A Novel Algorithm for Evaluating Anomaly Based Network Intrusion Detection Systems. *Sensors (Basel, Switzerland)*, 25(1). <https://doi.org/10.3390/S25010078>
- Baidar, R., Maric, S., & Abbas, R. (2025). *Hybrid Deep Learning-Federated Learning Powered Intrusion Detection System for IoT/5G Advanced Edge Computing Network*. <https://arxiv.org/pdf/2509.15555>
- Barkah, A. S., Selamat, S. R., Abidin, Z. Z., & Wahyudi, R. (2023). Data Generative Model to Detect the Anomalies for IDS Imbalance CICIDS2017 Dataset. *TEM Journal*, 12(1), 80–89. <https://doi.org/10.18421/TEM121-11>
- Blessing, L., & Chakrabarti, A. (2009). *DRM: A Design Research Methodology*. Canadian Institute for Cybersecurity. (2017). *Intrusion detection evaluation dataset (CIC-IDS2017)*. <http://cicresearch.ca/CICDataset/CIC-IDS-2017/>.
- Canadian Institute for Cybersecurity, & Communications Security Establishment. (2018). *CSE-CIC-IDS2018 on AWS*. University of New Brunswick & Amazon Web Services. <https://registry.opendata.aws/cse-cic-ids2018/>. <https://registry.opendata.aws/cse-cic-ids2018/>

- Cantone, M., Marrocco, C., & Bria, A. (2024). On the Cross-Dataset Generalization of Machine Learning for Network Intrusion Detection. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2024.3472907>
- Cipollone, F. (2025, Desember 5). *React4Shell (React2Shell) Is being exploited at scale: Critical Unauthenticated RCE in React RSC Flight (CVE-2025-55182) and Next.js (CVE-2025-66478) - Phoenix Security*. <https://phoenix.security/react2shell-cve-2025-55182-exploitation/>
- Dai, Z., Por, L. Y., Chen, Y. L., Yang, J., Ku, C. S., Alizadehsani, R., & Pławiak, P. (2024). An intrusion detection model to detect zero-day attacks in unseen data using machine learning. *PLOS ONE*, 19(9), e0308469. <https://doi.org/10.1371/JOURNAL.PONE.0308469>
- Devi, A., Prabhakaran, M. K., Prasanna Kumar, J. S., Nithish Kumar, J., Devi, A., Prabhakaran, M. K., Prasanna Kumar, J. S., & Nithish Kumar, J. (2025). Autoencoder-Based Anomaly Detection for Cyber Threat Monitoring. <https://services.igi-global.com/resolvedoi/resolve.aspx?doi=10.4018/979-8-3693-9919-4.ch004>, 59–80. <https://doi.org/10.4018/979-8-3693-9919-4.CH004>
- Ghazi, D., Hamid, H. S., Zaiter, M. J., Sabri, A., & Behadili, G. (2024). Snort Versus Suricata in Intrusion Detection. *Iraqi Journal of Information and Communication Technology*, 7(2), 73–88. <https://doi.org/10.31987/IJICT.7.2.290>
- Ghurab, M., Gaphari, G., Alshami, F., Alshamy, R., & Othman, S. (2021). A Detailed Analysis of Benchmark Datasets for Network Intrusion Detection System. *Asian Journal of Research in Computer Science*, 14–33. <https://doi.org/10.9734/AJRCOS/2021/V7I430185>
- Gopalan, S. S., Ravikumar, D., Linekar, D., Raza, A., & Hasib, M. (2021). Balancing Approaches towards ML for IDS: A Survey for the CSE-CIC IDS Dataset. *ICCSPA 2020 - 4th International Conference on Communications, Signal Processing, and their Applications, 2021-January*. <https://doi.org/10.1109/ICCSPA49915.2021.9385742>
- Guida, C., Nascita, A., Montieri, A., & Pescape, A. (2023). Cross-Evaluation of Deep Learning-based Network Intrusion Detection Systems. *Proceedings -*

- 2023 International Conference on Future Internet of Things and Cloud, FiCloud* 2023, 328–335.
<https://doi.org/10.1109/FICLOUD58648.2023.00055>
- Guo, Y. (2023). A Survey of Machine Learning-Based Zero-Day Attack Detection: Challenges and Future Directions. *Computer communications*, 198, 10.1016/j.comcom.2022.11.001.
<https://doi.org/10.1016/J.COMCOM.2022.11.001>
- Halbouni, A., Gunawan, T. S., Habaebi, M. H., Halbouni, M., Kartiwi, M., & Ahmad, R. (2022). CNN-LSTM: Hybrid Deep Neural Network for Network Intrusion Detection System. *IEEE Access*, 10, 99837–99849.
<https://doi.org/10.1109/ACCESS.2022.3206425>
- Help Net Security. (2024, April 24). *Global attacker median dwell time continues to fall - Help Net Security*. <https://www.helpnetsecurity.com/2024/04/24/2023-attacker-dwell-time/>
- Jay. (2025, Juli 28). *Zero-Day Attacks Explained: What CISOs Need To Know In 2025 - Bluefire Redteam*. <https://bluefire-redteam.com/zero-day-attacks-explained-what-cisos-need-to-know-in-2025/>
- Karatas, G., Demir, O., & Sahingoz, O. K. (2020). Increasing the Performance of Machine Learning-Based IDSs on an Imbalanced and Up-to-Date Dataset. *IEEE Access*, 8, 32150–32162.
<https://doi.org/10.1109/ACCESS.2020.2973219>
- Khalil, M. (2025, September 28). *Cybercrime 2025: \$10.5T Losses & Shocking New Statistics - Deepstrike*. <https://deepstrike.io/blog/cybercrime-statistics-2025>
- Korniszuk, K., & Sawicki, B. (2024). Autoencoder-Based Anomaly Detection in Network Traffic. *2024 25th International Conference on Computational Problems of Electrical Engineering, CPEE 2024*.
<https://doi.org/10.1109/CPEE64152.2024.10720411>
- Kristi, E., Tobing, A., Eka Septya, R., & Servanda, Y. (2025). Comparative Analysis of Network Security: Firewall, IDS, and AI-Based Defense Against DDoS Attacks. *Journal of Artificial Intelligence and Engineering Applications (JAIEA)*, 4(3), 1818–1822. <https://doi.org/10.59934/JAIEA.V4I3.1026>

- Lawall, A., & Zöllner, T. (2025). Impact of Target Network-Specific Data on the Performance of Machine-Learning-Based Intrusion Detection System Models. *2025 5th Intelligent Cybersecurity Conference, ICSC 2025*, 290–297. <https://doi.org/10.1109/ICSC65596.2025.11140289>
- Layeghy, S., Baktashmotlagh, M., & Portmann, M. (2023). DI-NIDS: Domain invariant network intrusion detection system. *Knowledge-Based Systems*, 273, 110626. <https://doi.org/10.1016/J.KNOSYS.2023.110626>
- Layeghy, S., & Portmann, M. (2023). Explainable Cross-domain Evaluation of ML-based Network Intrusion Detection Systems. *Computers and Electrical Engineering*, 108, 108692. <https://doi.org/10.1016/J.COMPELECENG.2023.108692>
- Le, T. T. H., Shin, Y., Kim, M., & Kim, H. (2024). Towards unbalanced multiclass intrusion detection with hybrid sampling methods and ensemble classification. *Applied Soft Computing*, 157. <https://doi.org/10.1016/j.asoc.2024.111517>
- Liao, J., Xu, X., Nguyen, M. C., Goodge, A., & Foo, C. S. (2024). COFT-AD: COntRastive Fine-Tuning for Few-Shot Anomaly Detection. *IEEE Transactions on Image Processing*, 33, 2090–2103. <https://doi.org/10.1109/TIP.2024.3374048>
- Liu, L., Engelen, G., Lynar, T., Essam, D., & Joosen, W. (2022). Error Prevalence in NIDS datasets: A Case Study on CIC-IDS-2017 and CSE-CIC-IDS-2018. *2022 IEEE Conference on Communications and Network Security, CNS 2022*, 254–263. <https://doi.org/10.1109/CNS56114.2022.9947235>
- Mao, J., Yang, X., Hu, B., Lu, Y., Yin, G., Mao, J., Yang, X., Hu, B., Lu, Y., & Yin, G. (2025). Intrusion Detection System Based on Multi-Level Feature Extraction and Inductive Network. *Electronics* 2025, Vol. 14, 14(1). <https://doi.org/10.3390/ELECTRONICS14010189>
- Mohale, V. Z., & Obagbuwa, I. C. (2025). Evaluating machine learning-based intrusion detection systems with explainable AI: enhancing transparency and interpretability. *Frontiers in Computer Science*, 7, 1520741. <https://doi.org/10.3389/FCOMP.2025.1520741/BIBTEX>
- Mohapatra, A., Jain, N., & Rudra, B. (2023). Intrusion Detection System in Networks Employing a Double-Layer Architecture Using Machine Learning

- Algorithms. 2023 14th International Conference on Computing Communication and Networking Technologies, ICCCNT 2023. <https://doi.org/10.1109/ICCCNT56998.2023.10307540>
- Osamor, F., & Wellman, B. (2023). A Deep Learning-Based Hybrid Model for Optimal Anomaly Detection. *Proceedings - 2023 Congress in Computer Science, Computer Engineering, and Applied Computing, CSCE 2023*, 650–656. <https://doi.org/10.1109/CSCE60160.2023.00111>
- Oyelakin, A., Ameen A.O, Ogundele T.S, Salau-Ibrahim T, Abdulrauf U.T, Olufadi H.I, Ajiboye I.K, Muhammad-Thani S, & Adeniji I. A. (2023). Overview and Exploratory Analyses of CICIDS 2017 Intrusion Detection Dataset. *Journal of Systems Engineering and Information Technology (JOSEIT)*, 2(2), 45–52. <https://doi.org/10.29207/joseit.v2i2.5411>
- Park, H., Shin, D., Park, C., Jang, J., Shin, D., Park, H., Shin, D., Park, C., Jang, J., & Shin, D. (2025). Unsupervised Machine Learning Methods for Anomaly Detection in Network Packets. *Electronics* 2025, Vol. 14, 14(14). <https://doi.org/10.3390/ELECTRONICS14142779>
- Rahmawati, T., Karna, N., Shin, S. Y., & Putra, M. A. P. (2024). Enhancing Network Security Through Real-Time Threat Detection with Intrusion Prevention System (Case Study on Web Attack). *Jurnal Ilmiah Teknik Elektro Komputer dan Informatika*, 10(4), 1004–1020. <https://doi.org/10.26555/JITEKI.V10I4.30380>
- Rosay, A., Cheval, E., Carlier, F., & Leroux, P. (2022). Network Intrusion Detection: A Comprehensive Analysis of CIC-IDS2017. *International Conference on Information Systems Security and Privacy*, 25–36. <https://doi.org/10.5220/0010774000003120>
- Roy, N., Tiwari, R. G., Roy, S., Agarwal, A. K., Garg, A., & Gupta, N. (2025). The Evolving Landscape of Network Threats: Classification, Defense Challenges, and Future Directions. *Proceedings of 8th International Conference on Computing Methodologies and Communication, ICCMC 2025*, 504–510. <https://doi.org/10.1109/ICCMC65190.2025.11140963>

- Salih, A., & Abdulazeez, A. (2021). Evaluation of Classification Algorithms for Intrusion Detection System: A Review. *Journal of Soft Computing and Data Mining*, 2(1), 31–40. <https://doi.org/10.30880/jscdm.2021.02.01.004>
- Scarfone, K., & Mell, P. (2007). *Special Publication 800-94 Guide to Intrusion Detection and Prevention Systems (IDPS) Recommendations of the National Institute of Standards and Technology*. https://tsapps.nist.gov/publication/get_pdf.cfm?pub_id=50951
- Sharafaldin, I., Lashkari, A. H., & Ghorbani, A. A. (2018). Toward generating a new intrusion detection dataset and intrusion traffic characterization. *ICISSP 2018 - Proceedings of the 4th International Conference on Information Systems Security and Privacy, 2018-January*, 108–116. <https://doi.org/10.5220/0006639801080116>
- Singh, A., & Jang, J. (2022). *Autoencoder-based Unsupervised Intrusion Detection using Multi-Scale Convolutional Recurrent Networks*. <https://arxiv.org/pdf/2204.03779>
- Sridharan, S., Patil, S., Shobha, T., & Pai, P. (2025). Hybrid Machine Learning–Based Intrusion Detection for Zero-Day Attack Prevention in Digital Education Networks. *International Journal of Safety and Security Engineering*, 15(8). <https://doi.org/10.18280/IJSSE.150815>
- Tariq, A. H. I. E., Tariq, M. B. I. E., & Lu, S. (2024). Hybrid AI-Driven Techniques for Enhancing ZeroDay Exploit Detection in Intrusion Detection System (IDS). *2024 3rd International Conference on Artificial Intelligence, Internet of Things and Cloud Computing Technology, AIoTC 2024*, 156–160. <https://doi.org/10.1109/AIOTC63215.2024.10748333>
- Verkerken, M., D’hooge, L., Wauters, T., Volckaert, B., & De Turck, F. (2021). Towards Model Generalization for Intrusion Detection: Unsupervised Machine Learning Techniques. *Journal of Network and Systems Management* 2021 30:1, 30(1), 12-. <https://doi.org/10.1007/S10922-021-09615-7>
- Xin, C., & Xu, K. (2025). Cross-Dataset Transformer-IDS with Calibration and AUC Optimization (Evaluated on NSL-KDD, UNSW-NB15, CIC-IDS2017). *Journal of Cyber Security*, 7(1), 483–503. <https://doi.org/10.32604/jcs.2025.071627>

- Yaddala, M., & Sunkara, Y. (2024). Comprehensive Survey of Web Security Threats in 2024. *International Journal of Scientific Research in Engineering and Management*. <https://doi.org/10.55041/IJSREM38614>
- Yue, Z., Zeng, H., Zhang, Y., Shang, L., & Wang, D. (2023). *MetaAdapt: Domain Adaptive Few-Shot Misinformation Detection via Meta Learning*. <http://arxiv.org/abs/2305.12692>
- Zugec, M. (2025, Desember 4). *Technical Advisory: React2Shell Critical Unauthenticated RCE in React (CVE-2025-55182) - Bitdefender*. <https://businessinsights.bitdefender.com/advisory-react2shell-critical-unauthenticated-rce-in-react-cve-2025-55182>